Nonlinear Leverage Effects in Asset Returns: Evidence from American and Japanese Stock Markets

Asahi Ushio*, Kenichiro McAlinn† and Teruo Nakatsuma‡

*Faculty of Science and Engineering, Keio University, Japan
†Department of Statistical Science, Duke University, USA
‡Faculty of Economics, Keio University, Japan

January 23rd, 2015

研究の背景

- 株価収益率のボラティリティの推定に関して、よく知られている現象の一つに「レバレッジ効果」がある．一般にレバレッジ効果とは今日のボラティリティと昨日の株価収益率の間に負の相関が見られることを指す．
- 先行研究 [例えば Hansen et al. (2011) や McAlinn et al. (2014)] では，レバレッジ効果を非線形関数（以下ではレバレッジ関数と呼ぶ）で表現し，ボラティリティ変動モデルに組み込むことが提案されている．
- レバレッジ関数としては多項式による近似が使われるが，株価指数に関する応用ではそれぞれ異なった次数の多項式がレバレッジ関数として有効であることが先行研究 [例えば McAlinn et al. (2014)] で示されている．
- このことからレバレッジ関数は個別銘柄でも異なることが示唆される．

本研究の概要

1. 非線形レバレッジ確率ボラティリティ (SV) モデルの構築
2. Auxiliary Particle Filter (APF) と Particle Learning (PL) による上記モデルの推定方法の提案
3. 日経 225，S&P500，NASDAQ100 の各構成銘柄に対する実証分析
4. 順序プロビット・モデルによる次数決定要因に関する分析

レバレッジ効果

- ある企業の株価が下落したときに，それに付随して株価収益率の分散（ボラティリティ）が大きくなることをレバレッジ効果という．この名前は，株式時価総額の減少に伴いバランスシートでの負債比率（レバレッジ）が高くなることに由来するとされる．
- 株価の収益率とボラティリティの間にはレバレッジ効果があることは広く知られているが，レバレッジ効果は相関係数を推定するだけでは必ずしも捉えられるとは限らない．何故なら相関係数は線形の関連性しか捉えられないからである (Leverage Puzzle).

レバレッジ効果の例: S& P500 の日次収益率と終値

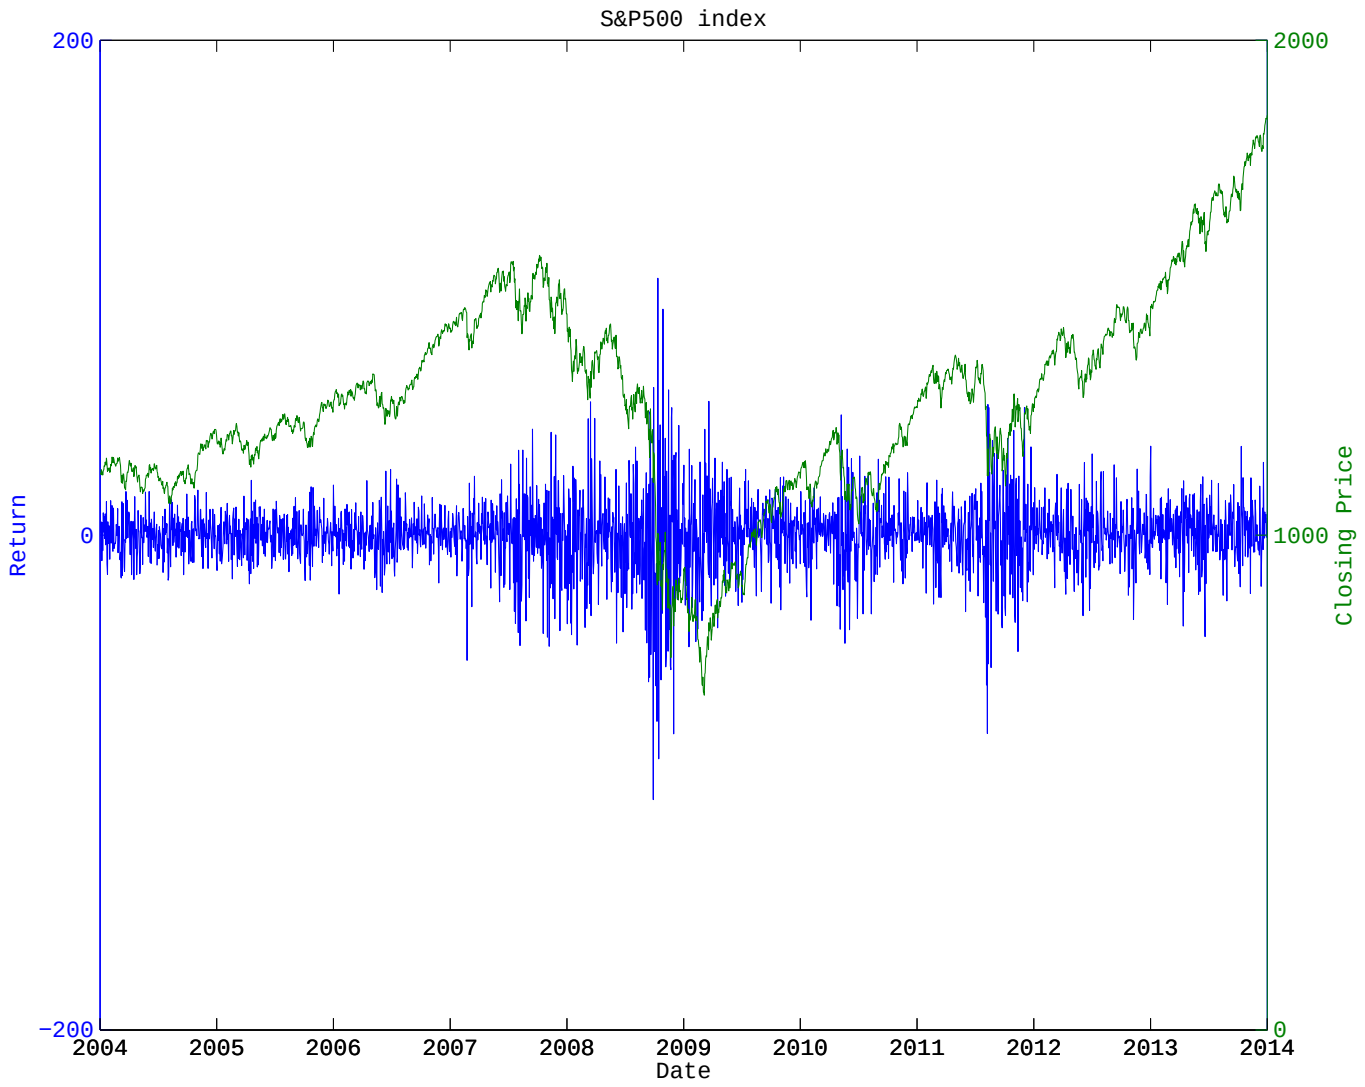

標準的な SV モデル

SV モデル

$$\begin{cases} y_t = \exp(\frac{x_t}{2})\epsilon_t \\ x_{t+1} = \mu + \beta x_t + \eta_t \end{cases} \tag{1}$$

$$\begin{bmatrix} \epsilon_t \\ \eta_t \end{bmatrix} \sim N\left(\begin{bmatrix} 0 \\ 0 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & \tau^2 \end{bmatrix} \right)$$

線形レバレッジ効果を持つ SV モデル

線形レバレッジ SV モデル

$$\begin{cases} y_t = \exp(\frac{x_t}{2})\epsilon_t \\ x_{t+1} = \mu + \beta x_t + \varphi \epsilon_t + \eta_t \end{cases} \tag{2}$$

$$\begin{bmatrix} \epsilon_t \\ \eta_t \end{bmatrix} \sim N\left(\begin{bmatrix} 0 \\ 0 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & \tau^2 \end{bmatrix} \right)$$

一般的なレバレッジ関数を持つ SV モデル

非線形レバレッジ SV モデル（一般形）

$$\begin{cases} y_t = \exp(\frac{x_t}{2})\epsilon_t \\ x_{t+1} = \mu + \beta x_t + \ell(\epsilon_t) + \eta_t \end{cases} \tag{3}$$

$$\begin{bmatrix} \epsilon_t \\ \eta_t \end{bmatrix} \sim N\left(\begin{bmatrix} 0 \\ 0 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & \tau^2 \end{bmatrix} \right)$$

$\ell(\epsilon_t) = \varphi\epsilon_t$ ならば、線形レバレッジ SV モデル (2) になる。

レバレッジ関数のエルミート多項式近似

(3) 式のレバレッジ関数 $\ell(\epsilon_t)$ のままでは推定できないため，これを k 次エルミート多項式 $\ell_k(\epsilon_t)$ で置き換えて推定可能な形にする.

エルミート多項式近似

- 近似されたレバレッジ関数 $l_k(\epsilon_t)$

$$l_k(\epsilon_t) = \varphi_1 H_1(\epsilon_t) + ... + \varphi_k H_k(\epsilon_t) \tag{4}$$

- $H_k(z)$ はエルミート多項式

$$H_k(z) = (-1)^k \exp(z^2/2) \frac{d^k}{dz^k} \exp(-z^2/2) \tag{5}$$

エルミート多項式の例

0 ∼ 6 次のエルミート多項式は以下のようになる.

$$
\begin{aligned}
H_0(z) &= 1 \\
H_1(z) &= z \\
H_2(z) &= z^2 - 1 \\
H_3(z) &= z^3 - 3z \\
H_4(z) &= z^4 - 6z^2 \\
H_5(z) &= z^5 - 10z^3 + 15z \\
H_6(z) &= z^6 - 15z^4 + 45z^2 - 15.
\end{aligned}
$$

- 次数 0 のときはレバレッジ無しの SV モデル (1) となる.
- 次数 1 のときは線形レバレッジ SV モデル (2) となる.

エルミート多項式の性質

1. z が標準正規分布に従う場合，任意の次数 k に対しエルミート多項式の期待値は 0 に等しくなる．

$$E(H_k(z)) = \int_{-\infty}^{\infty} H_k(z)\phi(z)dz = 0, \quad z \sim N(0,1)$$

ここで $\phi(z)$ は標準正規分布の確率密度関数である．

2. 各次数 k のエルミート多項式は下記の意味で互いに直交する．

$$E(H_j(z)H_k(z)) = \int_{-\infty}^{\infty} H_j(z)H_k(z)\phi(z)dz = \begin{cases} n! & (k=j) \\ 0 & (k \neq j) \end{cases}$$

3. エルミート多項式の列 $\{H_k\}_{k=0}^{\infty}$ は，

$$\int_{-\infty}^{\infty} |\ell(z)|^2 \phi(z)dz < \infty$$

を満たす連続なレバレッジ関数 ℓ の L^2 空間において直交基底を形成する．

非線形レバレッジ SV モデル

以上より本研究で用いたモデルは最終的に以下のように構築される.

非線形レバレッジ SV モデル（エルミート多項式近似）

$$\begin{cases} y_t = \exp(\frac{x_t}{2})\epsilon_t \\ x_{t+1} = \mu + \beta x_t + l_k(\epsilon_t) + \eta_t \end{cases} \tag{6}$$

$$\begin{bmatrix} \epsilon_t \\ \eta_t \end{bmatrix} \sim N\left(\begin{bmatrix} 0 \\ 0 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & \tau^2 \end{bmatrix} \right)$$

$$l_k(\epsilon_t) = \varphi_1 H_1(\epsilon_t) + ... + \varphi_k H_k(\epsilon_t) \tag{7}$$

非線形レバレッジ SV モデルのベイズ推定

推定の問題点

- (3) 式は非線形状態空間モデルの一種である.
- そのため解析的な尤度の評価が困難である.
- よって未知のパラメータ $\theta = (\mu, \beta, \varphi_1, \ldots, \varphi_k, \tau^2)$ の推定も難しい.
- さらに次数 k はモデル選択の手法で決定しなければならないが，尤度の評価が難しいため AIC などは使いずらい.

解決策: 逐次ベイズ推定

- 補助粒子フィルター (auxiliary particle filter) と粒子学習 (particle learning) を組み合わせて状態変数 x_t と未知のパラメータ θ のベイズ推定を行う.
- モンテカルロ近似によって周辺尤度を求め，最適な次数 k を選択する.

分析に使用したデータ

- 以下の株価指数の構成銘柄の日次収益率
  1. 日経 225(198 銘柄)
     Source: 日経 NEEDS
  2. NASADQ100(68 銘柄)
     Source: Bloomberg
  3. S& P500(417 銘柄)
     Source: Bloomberg
- 期間: 2004/1 $\sim$ 2013/12

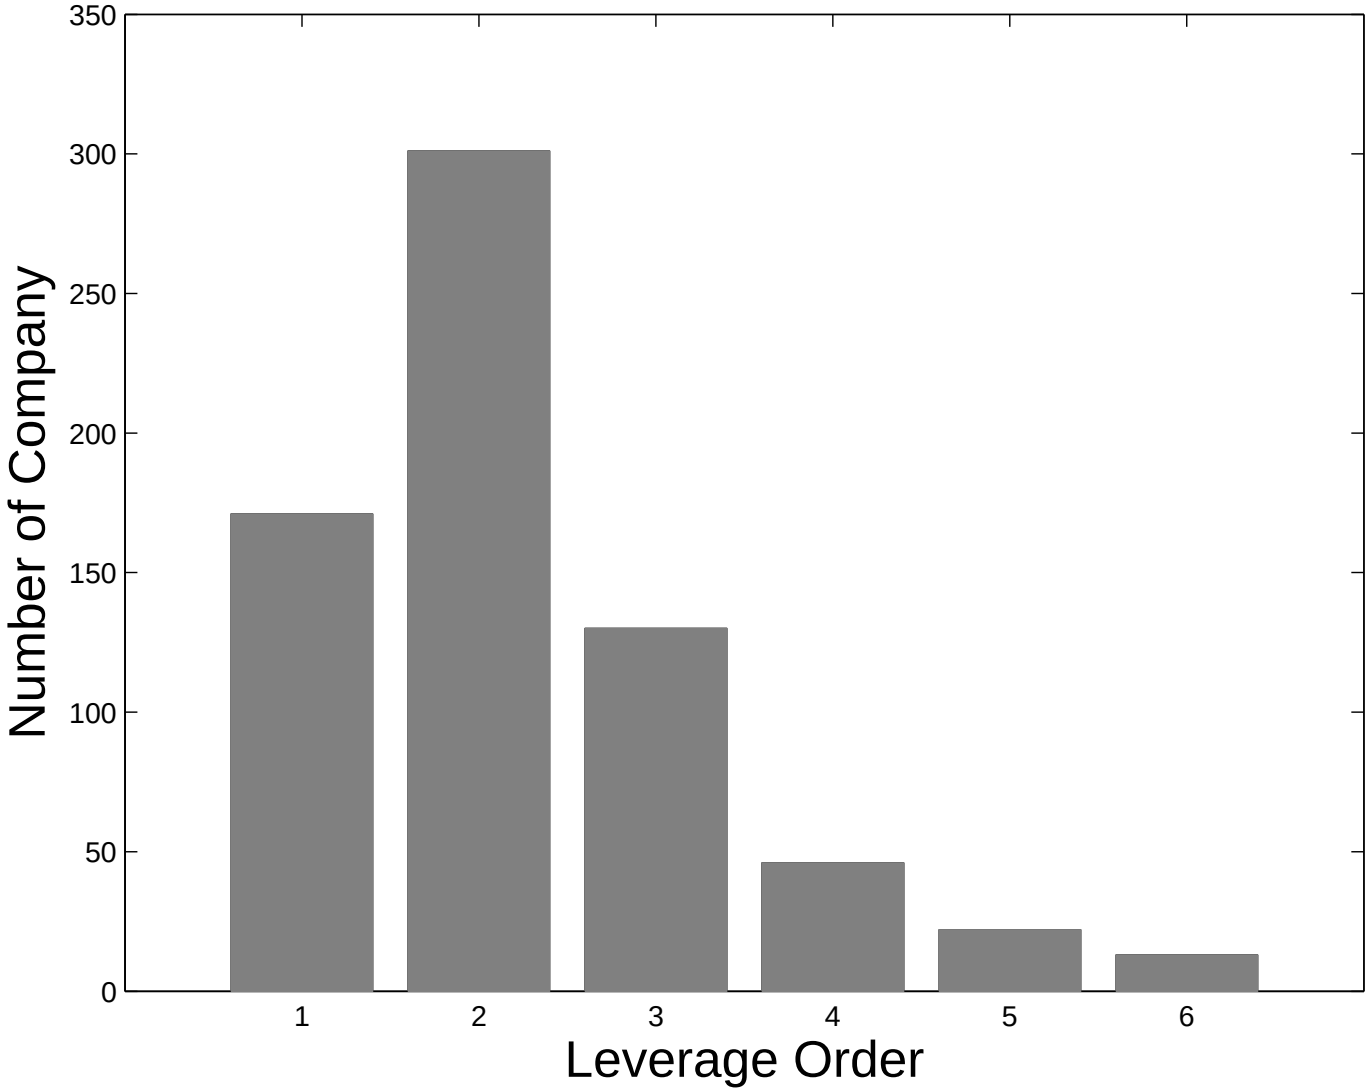

Figure: 全銘柄の結果

全銘柄での傾向

1. 2 次を有意とする銘柄が最も多い.
2. 1 次の銘柄の割合は 25%にすぎない.

   $\Rightarrow$ レバレッジ効果の非線形性が示唆される

3. 従来のような線形近似では，大多数の銘柄のレバレッジ効果をうまく近似できないことが分かる．(ほぼ 0 に等しくなる．)

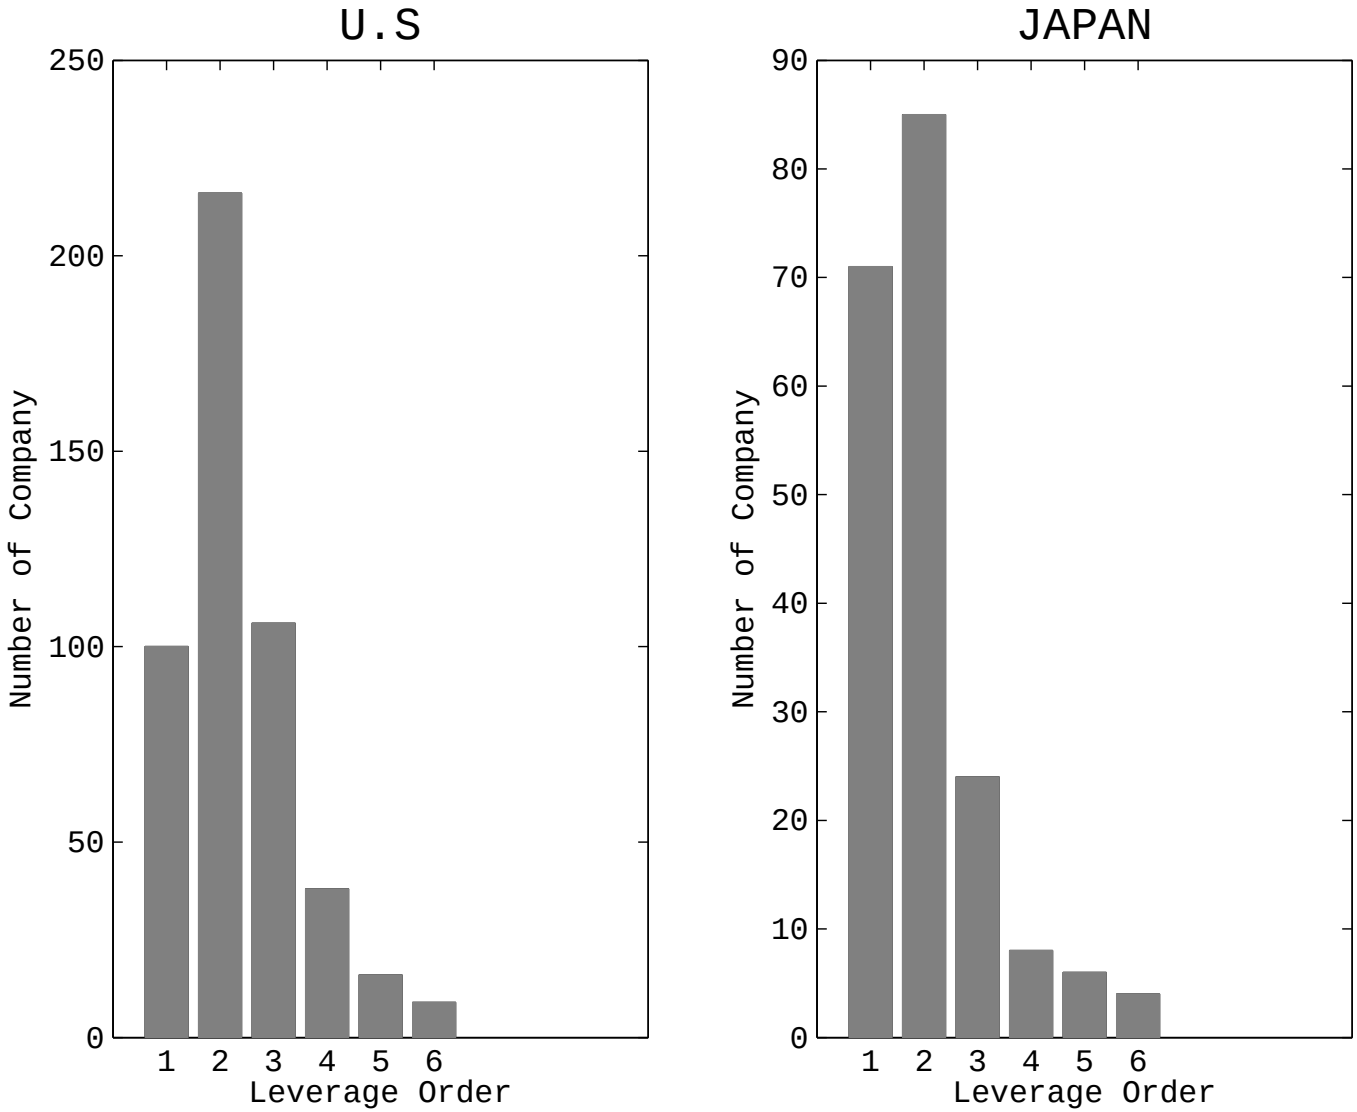

Figure: 国別の結果

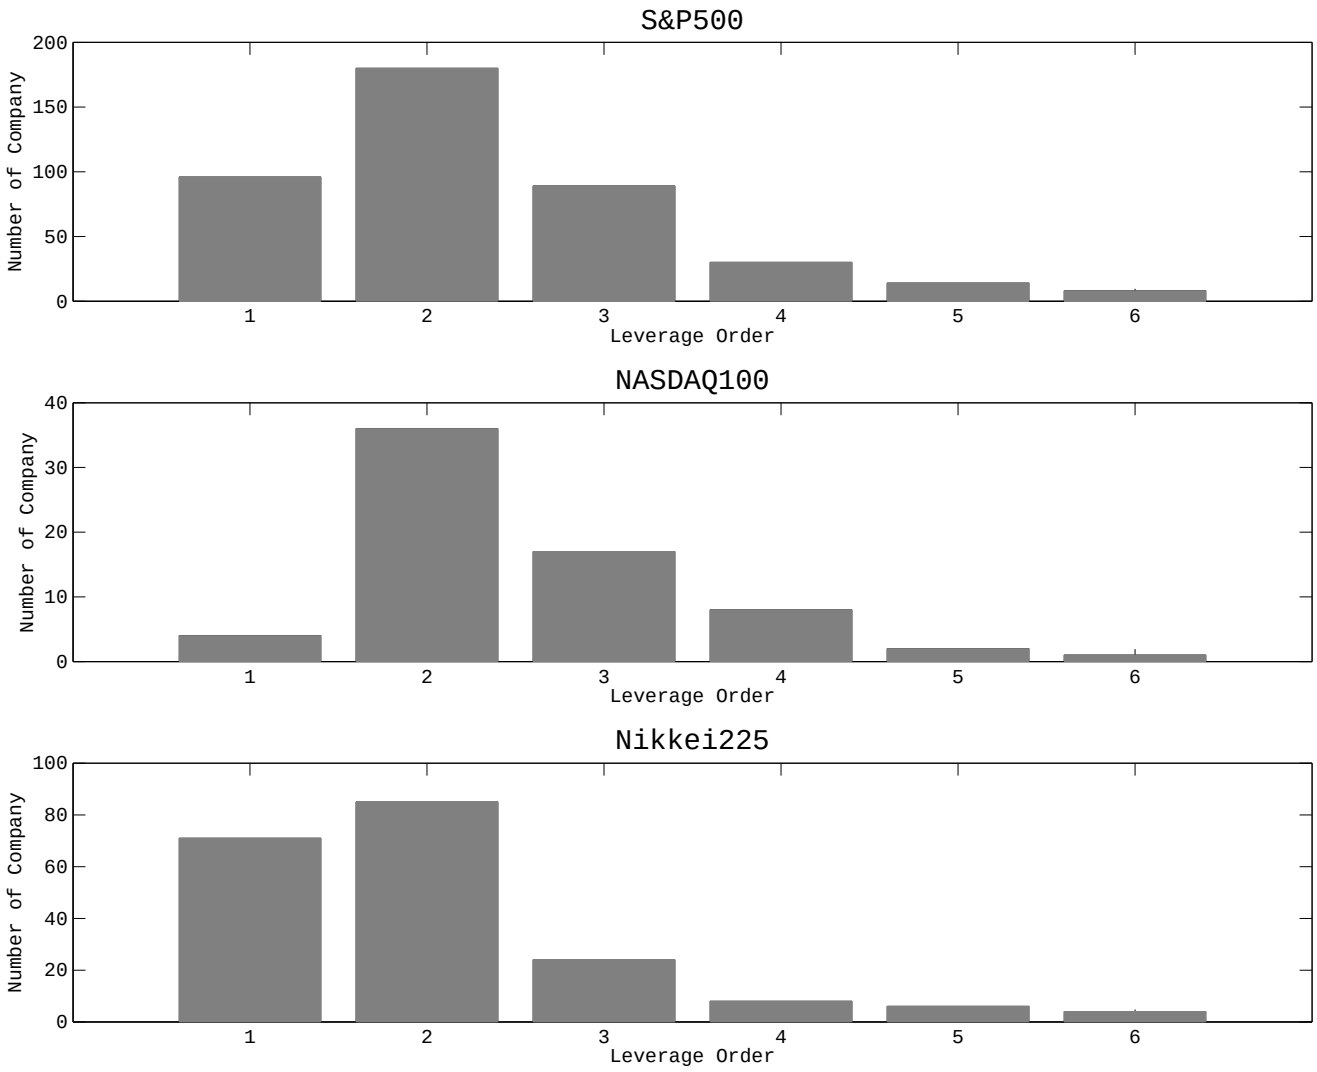

Figure: 市場別の結果

国別および市場別の結果

1. 国別，市場別でも 2 次の銘柄が最も多い.
2. 国別では
   - 1 次となる銘柄の割合は，米国が 21%となるのに対し日本は 36%であった.

   ⇒ 米国の方がアグレッシブな投資家が多く，非合理的な投資による影響が多いために複雑な形となっているのではないか
3. 市場別では
   - 日経 225 と S&P 500 の違いは国による違いと考えられる.
   - NASDAQ の銘柄が極端に一次銘柄が少ない.

   ⇒ NASDAQ が比較的若い企業の多い市場であることが原因か？

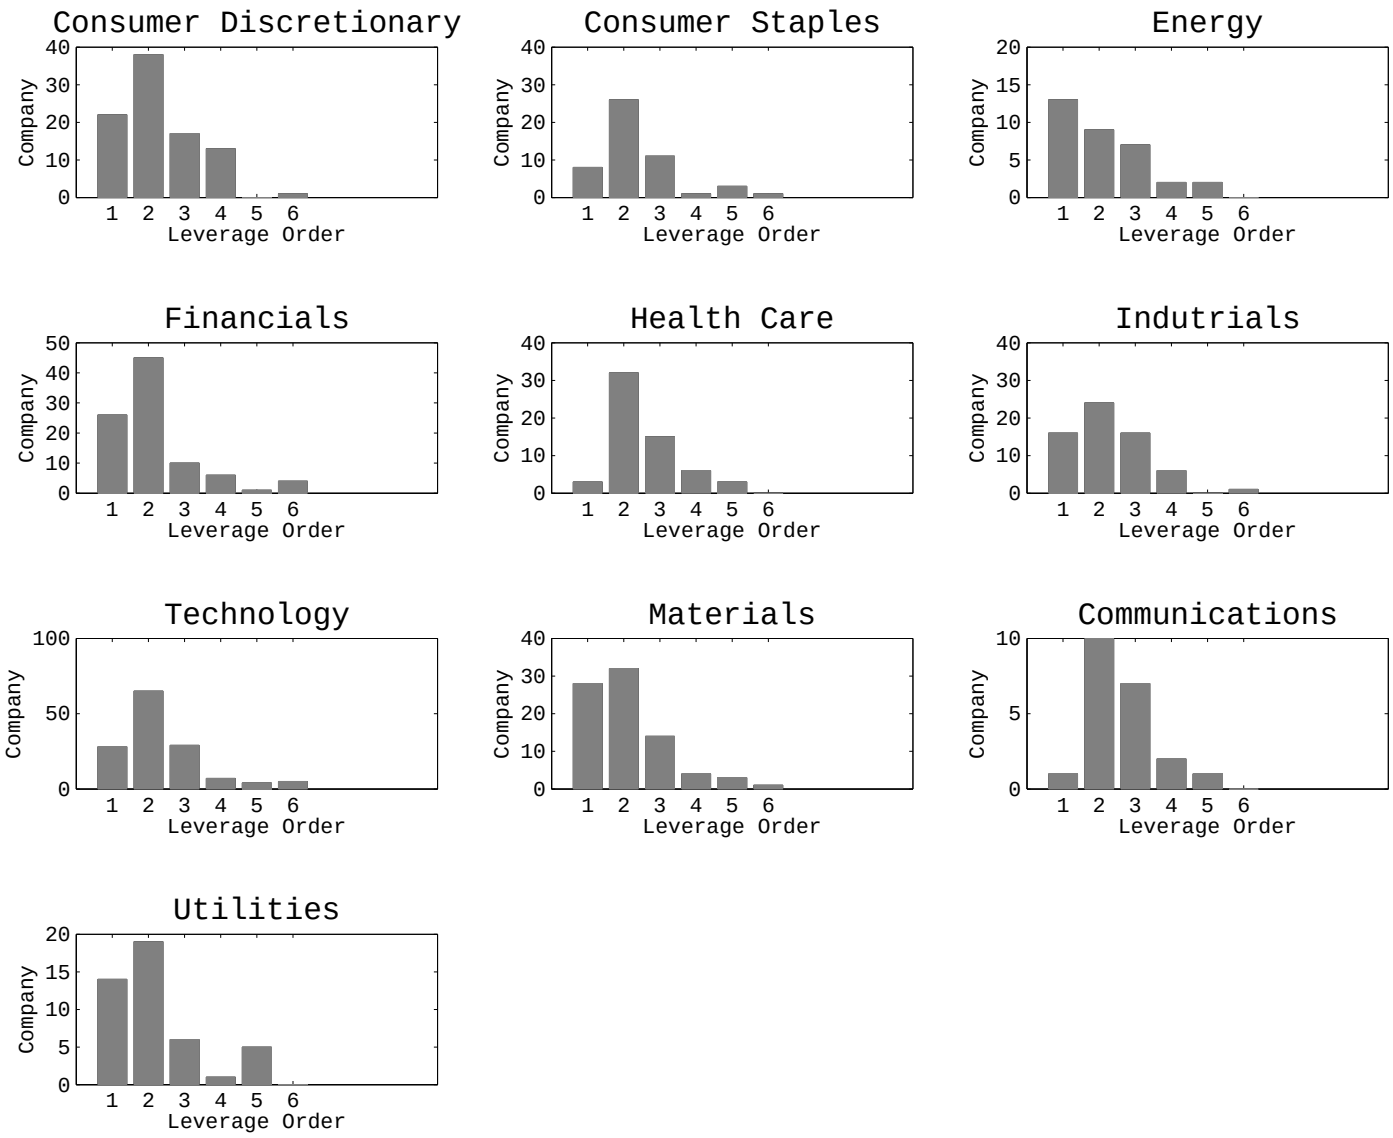

Figure: 業種別の結果

業種別の結果

- Energy が 1 次，それ以外は 2 次が多い.
- Technology，Health Care，Communications などは 1 次の割合がかなり低い.

$\Rightarrow$ 業種の違いも次数に影響がありそうである.

レバレッジ関数の形状

- レバレッジ関数の形状の主な違いは，次数及び最高次数の項にかかる係数の符号によって決まる.
- しかし，高次のレバレッジ関数も 95%区間の枠内では 2 次関数のような挙動を示す.
- 関数によっては株価収益率が下がったときにボラティリティを逓減させる方向へ働くものもある.

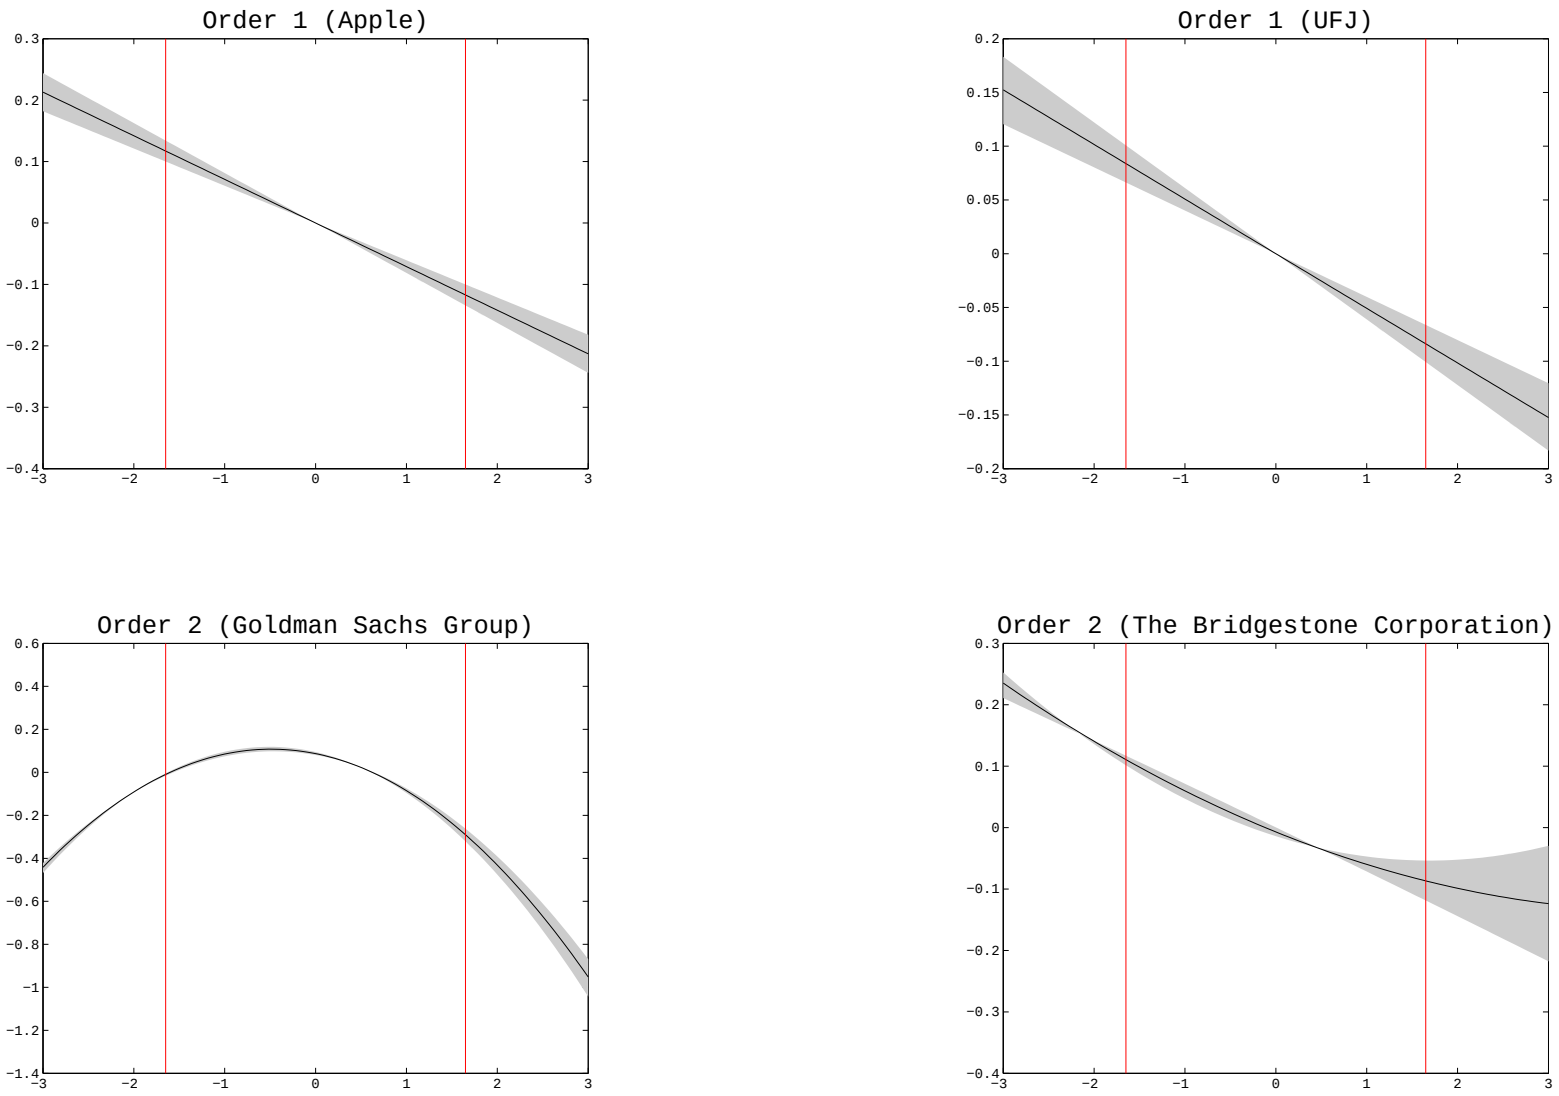

Figure: レバレッジ関数（1 次と 2 次）

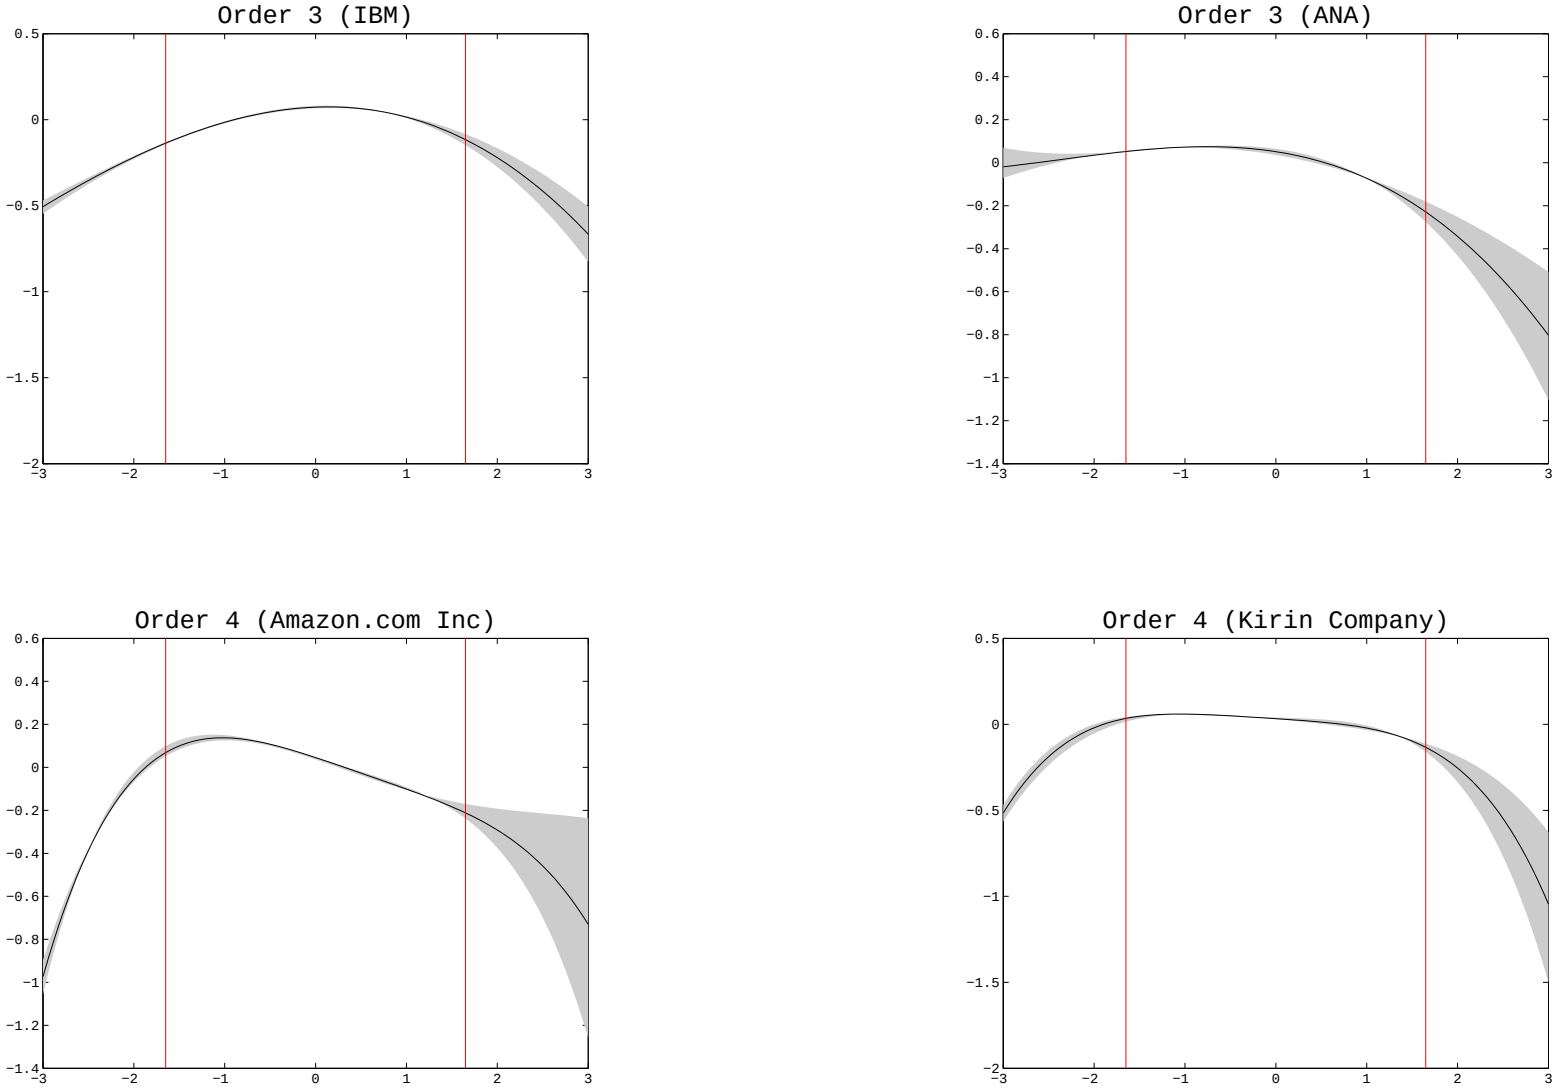

Figure: レバレッジ関数（3 次と 4 次）

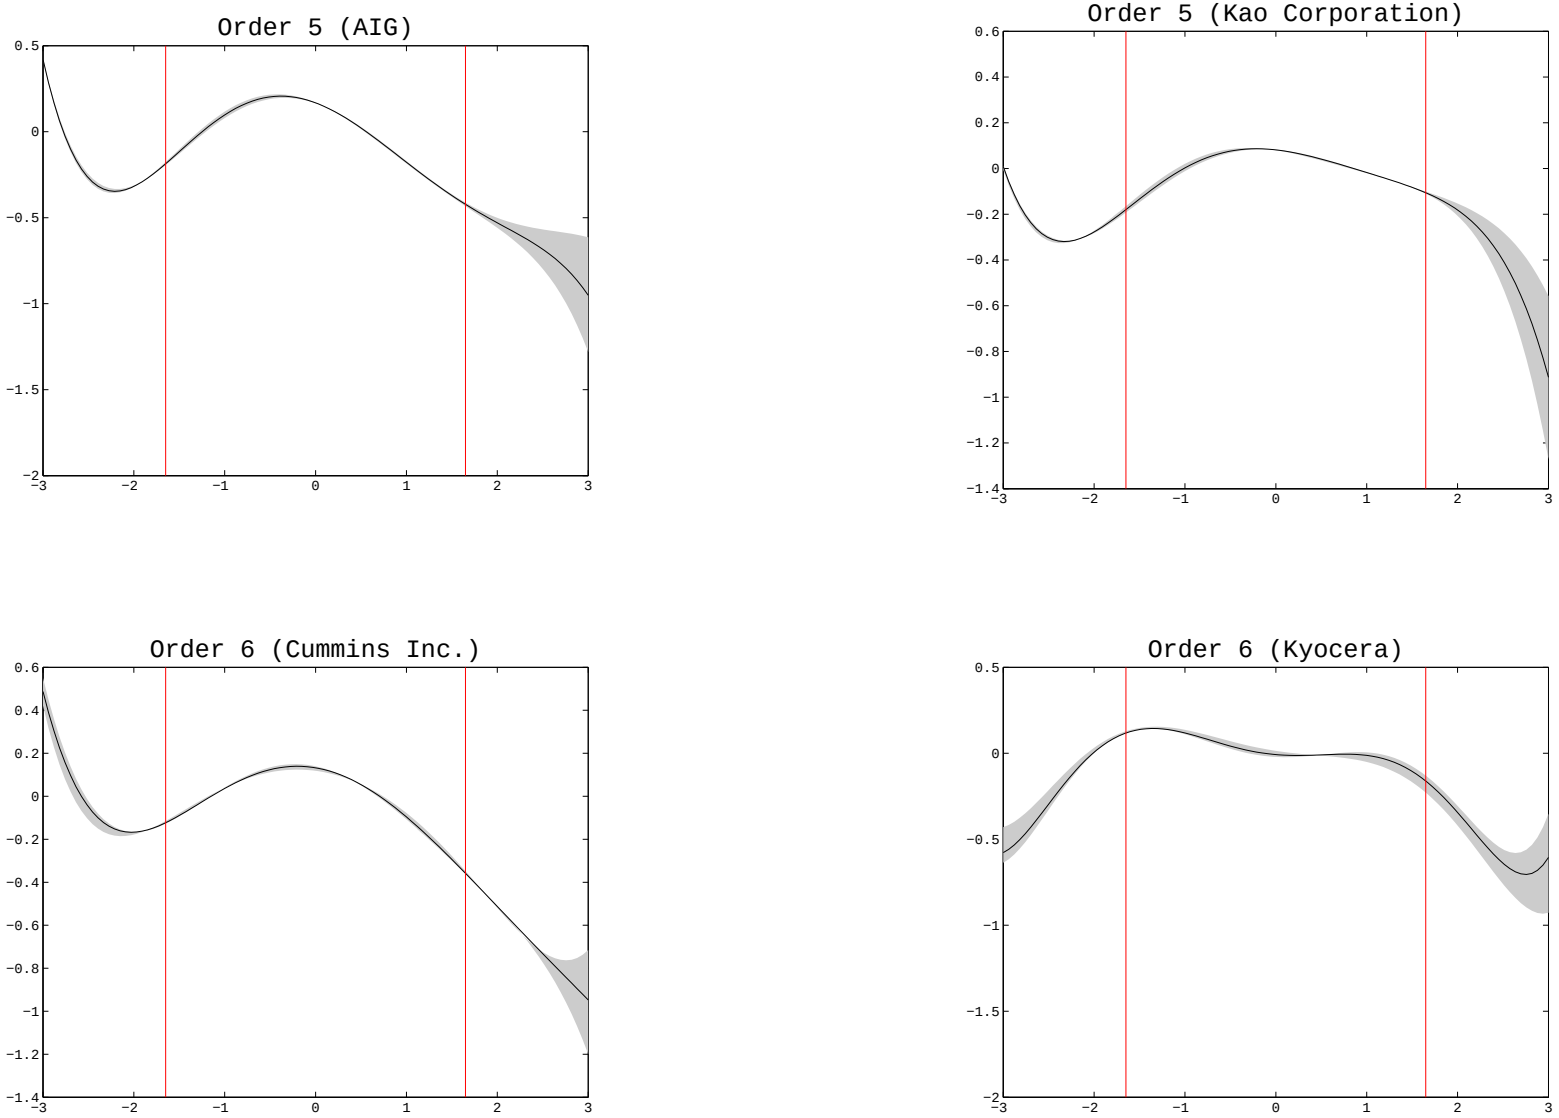

Figure: レバレッジ関数（5 次と 6 次）

Table: 最高次数の項にかかる係数の符号

Order	Nikkei225		S&P500		NASDAQ100	
Lev	Positive	Negative	Positive	Negative	Positive	Negative
1	24	47	3	93	0	4
2	18	67	3	177	0	36
3	6	18	62	27	10	7
4	4	4	8	22	0	8
5	1	5	6	8	1	1
6	1	3	5	3	1	0

順序プロビット・モデル

以上の分析からレバレッジ関数の次数は明らかに国や業種などに影響されている可能性が高い．以下ではどのような要因で次数の高低の差が出るのかを順序プロビット・モデルを推定して検証する．

順序プロビット・モデル

$$y_i^* = \text{constant} + \boldsymbol{\beta x_i} + u_i, \quad u_i \sim \mathcal{N}(0,1) \tag{8}$$

$$y_i = \begin{cases} 1\ (\mu_0 \leq y_i^* < \mu_1), \\ 2\ (\mu_1 \leq y_i^* < \mu_2), \\ 3\ (\mu_2 \leq y_i^* < \mu_3), \\ 4\ (\mu_3 \leq y_i^* < \mu_4), \\ 5\ (\mu_4 \leq y_i^* < \mu_5), \\ 6\ (\mu_5 \leq y_i^* < \mu_6), \end{cases} \quad \begin{array}{l} \boldsymbol{x_i'} = [x_{i,1}, ..., x_{i,12}] \\ \boldsymbol{\beta} = [\beta_1, ..., \beta_{12}] \end{array}$$

- 説明変数は以下のように設定する.

$$
\begin{aligned}
x_{i,1} &: \text{国別ダミー変数}\quad (\text{日本株なら } x_{i,1}=1) \\
x_{i,2} \sim x_{i,10} &: \text{業種別ダミー変数}\quad (\text{銘柄 } i \text{ が業種 } k \text{ に属せば } x_{i,k}=1) \\
x_{i,11} &: \text{ボラティリティー} \\
x_{i,12} &: \text{流動性（売買出来高）}
\end{aligned}
$$

- モデルの推定には，Albert and Chib (1993) に従いギブスサンプラーを用いた.
- 業種ダミー変数は Finance を基準としている.

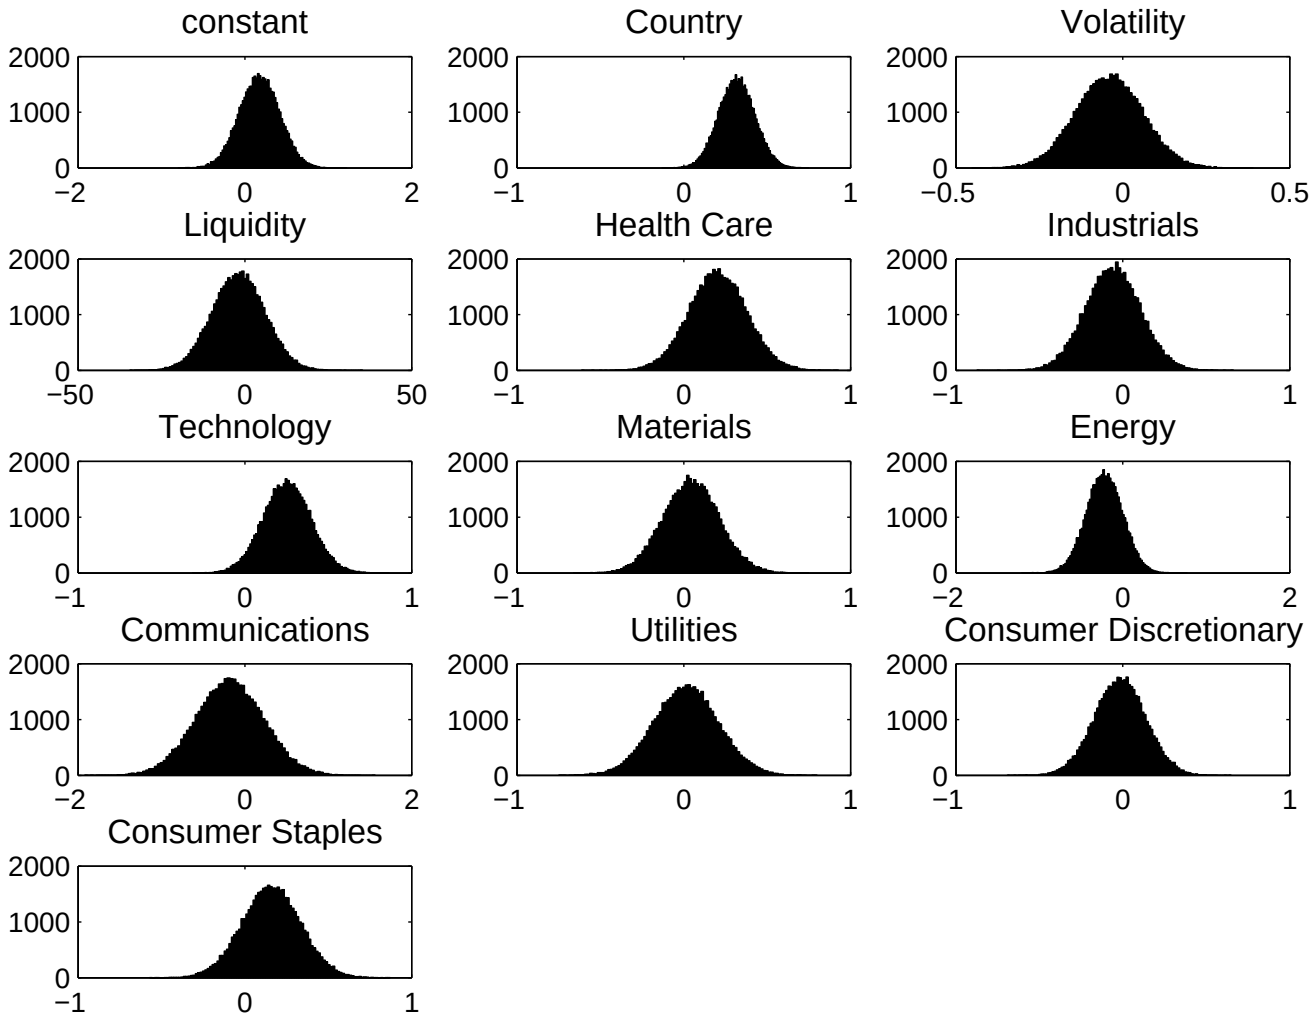

Figure: ギブズサンプラーによって生成した係数のヒストグラム

Table: 事後平均と 95% 信用区間

Parameter	constant	Country	Volatility	Liquidity
Posterior mean	0.176	0.318	-0.040	-1.894
CI	[-0.292 0.644]	[0.107 0.532]	[-0.237 0.157]	[-17.341 13.547]
	Sector			
Parameter	Health Care	Industrials	Technology	Materials
Posterior mean	0.205	-0.059	0.253	0.044
CI	[-0.135 0.544]	[-0.380 0.267]	[-0.027 0.535]	[-0.284 0.377]
	Sector			
Parameter	Energy	Communications	Utilities	Consumer Discretionry
Posterior mean	-0.219	-0.182	0.015	-0.016
CI	[-0.648 0.207]	[-0.980 0.619]	[-0.363 0.399]	[-0.320 0.286]
	Sector			
Parameter	Consumer Staples			
Posterior mean	0.159			
CI	[-0.187 0.503]			

推定結果の考察

- 国はかなり明らかに要因として働いている.
- ボラティリティや流動性は全く影響を与えていない.
- Technology が正，Energy が負に働いている．しかし事後分布の 95%信用区間が 0 を含んでいるため，結論はそれほど強くはない.

結論

- 本研究では，エルミート多項式近似による非線形レバレッジ関数を持つ SV モデルを日米の主要株価指数採用銘柄の日次収益率に対して推定した.
- 推定の結果，日米の主要株価指数採用銘柄のレバレッジ効果には非線形性があることがわかり，従来型の線形レバレッジ関数は必ずしも適切とは言えないことが示唆された.
- 国や業種によってレバレッジ関数の次数に顕著な差が見られた.
- このレバレッジ関数の差に影響を与える要因を順序プロビット・モデルによって検証したところ，国と特定の業種が影響を与えている可能性が分かった.