社団法人　電子情報通信学会
THE INSTITUTE OF ELECTRONICS,
INFORMATION AND COMMUNICATION ENGINEERS

信学技報
TECHNICAL REPORT OF IEICE.

クリックベイトなニュース記事の特定に向けたユーザ行動分析

関　喜史† 潮　旭†† 米田　武† 松尾　豊†††

† 株式会社 Gunosy
〒 106–6125 東京都港区六本木 6–10–1 六本木ヒルズ森タワー 25F
†† 慶應義塾大学
〒 223–8522 神奈川県横浜市港北区日吉 3–14–1
††† 東京大学
〒 113–8654 東京都文京区本郷 7 – 3 – 1
E-mail: †{yoshifumi.seki,takeshi.yoneda}@gunosy.com, ††ushioasahi@keio.jp,
†††matsuo@weblab.t.u-tokyo.ac.jp

あらまし　クリックベイトは釣りとも呼ばれ, ニュース記事のタイトルを過剰に表現することでユーザの閲覧行動を誘発する行為のことであり, 近年問題になっている. クリックベイトなニュース記事を閲覧すると, 配信したニュース配信サービスのユーザ満足度が低下してしまうと考えられる. 本発表では将来的なクリックベイトなニュース記事の特定と排除のために, ニュース記事のテキスト情報と滞在時間の比較分析について報告する.

キーワード　自然言語処理, テキストマイニング, ユーザ行動分析

Analyzing User Behavior in News App towards Detecting Click-Bait News

Yoshifumi SEKI†, Asahi USHIO††, Takeshi YONEDA†, and Yutaka MATSUO†††

† Gunosy Inc.
Roppongi Hills Mori Tower 25F, 6–10–1 Minato-ku, Tokyo, 106–6125 Japan
†† Keio University
3–14–1, Hiyoshi, Kouhoku-ku, Yokohama, Kanagawa, 223–8522 Japan
††† The University of Tokyo
7–3–1, Hongo, Bunkyo-ku, Tokyo, 113–8522 Japan
E-mail: †{yoshifumi.seki,takeshi.yoneda}@gunosy.com, ††ushioasahi@keio.jp,
†††matsuo@weblab.t.u-tokyo.ac.jp

Abstract　クリックベイトは釣りとも呼ばれ, ニュース記事のタイトルを過剰に表現することでユーザの閲覧行動を誘発する行為のことであり, 近年問題になっている. クリックベイトなニュース記事を閲覧すると, 配信したニュース配信サービスのユーザ満足度が低下してしまうと考えられる. 本発表では将来的なクリックベイトなニュース記事の特定と排除のために, ニュース記事のテキスト情報と滞在時間の比較分析について報告する. TODO: アブスト英語化

Key words　Natural Language Processing, Text Mining, User Activity Analysis

1. はじめに

近年ニュースの閲覧行動は大きく変化している．2016 年 3 月の LINE 株式会社による「世代間のニュースサービス利用に関する意識調査」によれば，84%がニュース閲覧時に利用するデバイスとしてスマートフォンを挙げ，テレビの 61%を大きく上回った [1]．50 代,60 代は 40%以上が新聞を利用すると回答したものの，10 代,20 代では 20%前半に留まっている．このように多くの人々がニュースを読む際にスマートフォンを利用するようになっている．

スマートフォンでのニュース閲覧の増加に伴い，スマートフォンでの閲覧に特化した新興のニュース媒体も数多く誕生している．スマートフォンのニュース閲覧においては，Yahoo ニュース(注1), グノシー(注2),SmartNews(注3)のようなニュースアプリや，

(注1)：https://news.yahoo.co.jp/
(注2)：https://gunosy.com
(注3)：https://www.smartnews.com/

Twitter(注4),Facebook(注5),LINE(注6)のような SNS(Social Networking Service) がよく用いられている．新興のニュース媒体社はこのようなニュースアプリや SNS からの流入を効果的に獲得することで PV(ページビュー) を急激に増加させている．以前はウェブにおいて PV を高めることが収益に直接つながらないこともあったが，近年では広告技術の進歩により PV を高めることによって媒体社は収益を得ることが可能になった．このような背景から新興のニュース媒体が急成長している．

一方で PV を高めることを目指した媒体運営のために問題も起こっている．アメリカ大統領選やイギリスの EU 離脱問題て注目されたフェイクニュースはその代表的な問題である [2]．フェイクニュースは事実ではない情報を事実であるかのようにニュース記事として配信し，SNS で多くシェアされることによって PV を獲得することを狙っている．また近年話題になったキュレーションメディアに関する問題も，不正確な内容のウェブページを，専門知識がない編集者によって大量に生み出していた問題であり，安価に大量の PV を獲得することを狙っていた．本研究で取り上げるクリックベイトもこうした問題の一つである．

本研究で対象とするクリックベイトとは釣り記事とも呼ばれ，過度に扇情的なタイトルをつけることで利用者の関心を引くことを目的としたニュース記事のことである．新聞が中心だった以前は，ニュース記事のタイトルは見出しと呼ばれており，見出しは本文を十分に要約したものにすることが推奨されていた．しかし新聞は購読した時点で収益が発生するのに対し，ニュースアプリや SNS においてはニュース記事の閲覧を行わないと PV が発生しないことから，タイトルを扇情的にすることでユーザを惹きつけ，PV 数を増やそうという試みを様々な媒体社が行っているが，その試みが行き過ぎてしまうことをクリックベイトと呼ぶ．クリックベイトなニュース記事を利用者が閲覧してしまうと利用者は騙されたと感じ，そのニュース記事や媒体社だけでなく利用していたニュースアプリや SNS に対して不満を持ってしまうことが考えられる．そのためクリックベイトなニュース記事を特定し，利用者が閲覧してしまわないようにすることは重要である．

しかしクリックベイトは明確な線引をすることが難しい．フェイクニュースの場合は嘘であるということのため，どれがフェイクニュースかは一意に定まる．しかしクリックベイトの場合は,「騙された」という主観的な基準となるため明確な基準を設けることが困難である．ニュース媒体としても明確に線引をすることが難しいため,「茹でガエルの法則」のように悪意がないままにクリックベイトなニュース記事を配信してしまうことも考えられる．このような背景から, 我々は利用者が「騙された」と感じたことをサービス内での行動から特定することを目指している．

本報告ではニュース記事における滞在時間の短さに着目する．「騙された」と感じるニュース記事には様々なものがあるが，中でも閲覧してすぐに「騙された」と感じるようなニュース記事に着目する．そのようなニュース記事は滞在時間が著しく短いのではないかと考え，滞在時間が著しく短いニュース記事を対象に分析を行った．定性的な分析から滞在時間が著しく短いニュース記事を類型化し，その中でクリックベイトといえるものを示す．その上で滞在時間が著しく短いニュース記事の中からクリックベイトなニュース記事を特定することを試みる．

2. ニュース記事の滞在時間分析

本章ではニュース記事の滞在時間について分析を行う．まず分析対象となるデータの詳細について述べる．

2.1 分析データ

本節では分析対象のデータについて述べる．本研究ではスマートフォン向けアプリケーションであるグノシーにおける 2017 年 7 月 1 日 0 時から 2017 年 7 月 7 日 24 時までのニュース記事の閲覧データを分析する．

分析対象にはニュース記事データと，ニュース記事に対するユーザ行動データがある．ニュース記事データはその期間に閲覧されたニュース記事に関するデータであり，ニュース記事のカテゴリ, タイトル， サイムネイル画像, 本文データを含む．グノシーではニュース記事をカテゴリ別に分けて表示しており，表示されたニュース記事にはカテゴリが与えられている．このカテゴリは，幾つかのルールと教師あり学習器によって決定されている．本研究では「政治」,「経済」,「社会」,「国際」,「テクノロジー」,「スポーツ」,「エンタメ」,「コラム」の 8 つのカテゴリのニュース記事を扱う．ユーザ行動データはユーザが対象となるニュース記事に何秒滞在したかと，そのニュース記事の長さがどれだけであったが含まれている．ユーザが同じニュース記事を複数回閲覧することも考えられるため，そのユーザのニュース記事に対する最大の滞在時間を代表値とする．ニュース記事の長さはスマートフォンの機種によって取得が難しいものがあるため，今回は長さを取得できたユーザの行動データのみを利用している．分析対象とするニュース記事の滞在時間には各ニュース記事のユーザごとの滞在時間の中央値を用いる．以降本研究でニュース記事の滞在時間というときは，ニュース記事を閲覧したユーザの滞在時間の中央値を指すこととする．滞在時間はユーザがスマートフォンを開いたまま放置したケース等，著しく長い値になることがあるため平均値を代表値にすることは適さない．

データセットの特性について述べる．データセット中のニュース記事の閲覧数と順位をそれぞれ対数軸で表示したものを図 1 に示す．このように一部のニュース記事が多く閲覧され，多くのニュース記事は比較してほとんど閲覧されない．本研究の目的は過度に閲覧を誘発するようなニュース記事を特定することであるため，そのようなニュース記事は多く閲覧されていると考え，閲覧数の多いニュース記事のみを対象とすることを考える．またニュース記事の閲覧回数の傾向はカテゴリごとに異なり, よく閲覧されるカテゴリとあまり閲覧されないカテゴリがある．以上を踏まえ，各カテゴリの閲覧数が上位 10%になる

(注4) : https://twitter.com/
(注5) : https://www.facebook.com/
(注6) : https://line.me/

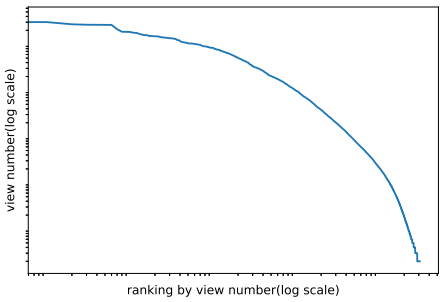

図 1　閲覧数と順位

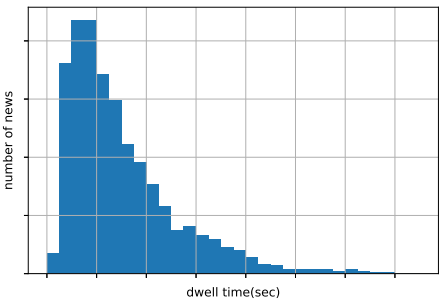

図 2　滞在時間のヒストグラム

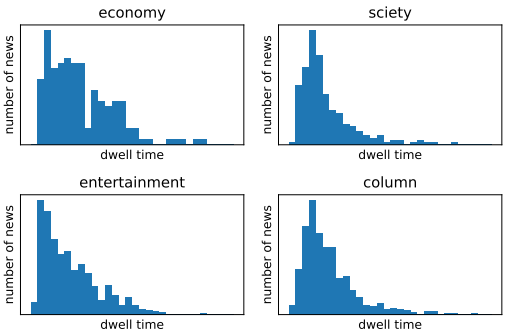

図 3　カテゴリ別の滞在時間のヒストグラム

ニュース記事のみを対象とすることにする．

このようにして得られた各カテゴリでよく閲覧されたニュース記事と，そのニュース記事の滞在時間を用いて分析を行う．

2.2　滞在時間の分析

本節ではニュース記事における滞在時間の分析を行う．まず図 2 にニュース記事全体の滞在時間のヒストグラムを示す．各度数は等間隔である．可視化のために滞在時間があるしきい値以上のニュース記事は対象にしていないが，これにより排除されたニュース記事は全体の 0.5%以下である．全体の分布は滞在時間が比較的短いところにピークがあり，そこから減少していくような分布になっている．

次にカテゴリ別での比較を行う．「経済」「社会」「エンタメ」「コラム」の滞在時間の分布を図 3 に示す．x 軸はすべてのカテゴリで共通であり，図 2 と共通である．y 軸は各カテゴリの最大の度数に応じて異なる．経済カテゴリはピークは短いところにあるものの，減衰は急激ではなく比較的長く読まれるニュース記事が多いことがわかる．社会カテゴリは減衰傾向は全体と同様だがピークより短い滞在時間のニュース記事が全体や他のカテゴリに比べて少なく，一定時間読まれているニュース記事が多いことがわかる，エンタメカテゴリはピークが全体よりも短いところにあり，またピークよりも短い滞在時間のニュース記事も多い．これはすぐ読むのをやめてしまうニュース記事が多いのではないかと考えられる．コラムカテゴリは，ピークより短い滞在時間のニュース記事も多いが，ピーク以降の記事数の減衰が緩やかである．このことから比較的長く読まれるニュース記事も，すぐ読むのをやめてしまうニュース記事も一定数あることを示唆している．このようにカテゴリごとに滞在時間の分布の特性が異なる．

カテゴリ	相関係数
政治	0.600
経済	0.477
社会	0.482
国際	0.527
テクノロジー	0.305
スポーツ	0.559
エンタメ	0.267
コラム	0.349

表 1　記事長と滞在時間の相関係数

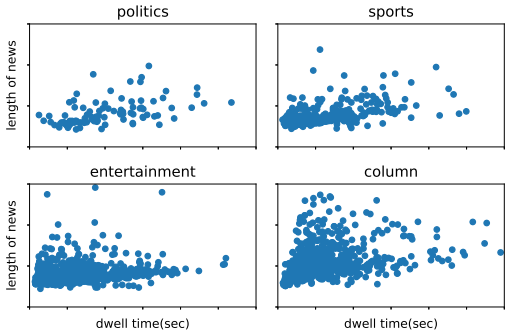

図 4　カテゴリ別の滞在時間と記事長の散布図

次に滞在時間とニュース記事の長さの関係について確認する．ユーザがすべてのニュース記事を最後まで読むという前提のもとでは，滞在時間はニュース記事の長さに相関すると考えられる．そこでピアソンの相関係数を用いてニュース記事の滞在時間とニュース記事の長さの相関をニュース記事全体とカテゴリごとに求める．結果を表 1 に示す．全体の相関係数は 0.3 程度と高くないが，カテゴリ別にみると「政治」「経済」「社会」「国際」「スポーツ」が 0.5 程度となっており，これらのカテゴリでは比較的ニュース記事の長さと滞在時間に相関があることがわかる．一方で「テクノロジー」「エンタメ」「コラム」の相関係数は 0.3 程度と高くなく, ニュース記事の長さと滞在時間の相関が小さいことがわかる．

そこで相関が比較的強い「政治」「スポーツ」, 相関が比較的弱い「エンタメ」「コラム」の滞在時間と記事長の散布図を図 4 に示す．各グラフの x 軸と y 軸は共通である．相関が弱い要因

には,「記事長が短いニュース記事の滞在時間が長い」か「記事長が長いニュース記事の滞在時間が短い」の 2 つがある．散布図をみると「記事長が短いニュース記事の滞在時間が長い」ケースはほとんどなく,「記事長が長いニュース記事の滞在時間が短い」ケースが多い事がわかる．そして相関が比較的弱い「エンタメ」|「コラム」ではその傾向が顕著に確認できる．クリックベイトなニュース記事を閲覧したユーザの行動として考えられる行動の 1 つはニュース記事を最後まで閲覧せずに離脱してしまうことである．記事長が長く滞在時間が短いニュース記事ではそのような行動が起こっている可能性があるが，ある程度で満足したために離脱している可能性もある．

以上の分析を踏まえ本研究では対象を限定するために滞在時間が著しく短いニュース記事に着目し，クリックベイトなニュース記事の類型化と特定を試みる．ユーザの滞在時間の傾向は記事長やカテゴリによって様々に異なるため，単純に類型化することは難しい．しかし滞在時間が著しく短いニュース記事はユーザが閲覧してすぐに離脱していると考えられる．単一の行動のみに絞りこめるため単純になること，記事長やカテゴリによって異なるものではないことから，類型化が容易になり，特定もしやすくなることが期待される．

3. 滞在時間が著しく短いニュース記事の定性的な分析

3.1 滞在時間が著しく短いニュース記事の類型化

本章では滞在時間が著しく短いニュース記事の定性的な分析を行う．ここで滞在時間が著しく短いニュース記事がすべてクリックベイトなニュース記事ではないことに注意する．我々は以前に滞在時間が短いニュース記事をユーザに表示されにくくする試みを行ったが, 一部のユーザの満足度を低下させる結果になった [3]．そのためまず滞在時間が短いニュースを定性的に分析し, どのようなニュース記事がクリックベイトなニュース記事であるのかを類型化することを試みた．

滞在時間が著しく短いニュース記事を観察すると, 以下のようなケースを確認することができた．

(a) タイトルに情報量が十分にあり, タイトルと本文が一致しているケース

(b) タイトルから期待される情報が本文に無いことがひと目で分かるケース

(c) 画像を想起するようなタイトルであり, 大きな画像を見ることで情報欲求が十分満たされたと考えられるケース

(d) 画像を想起するようなタイトルであるものの, 期待される画像が本文中にないケース

(a) のケースは例えば A 氏が B 市市長選で当選というようなニュース記事であり,A 氏の詳細なプロフィールがニュース記事中にあるものの, 多くのユーザはその事実で満足しているように見える．(b) のケースは例えば「タレント A さんがタレント B さんに告白した」というタイトルのニュース記事であるが、実際は A さんと B さんが主演したドラマの記者発表で行われたドラマのシーンについての話であるようなケースである．こうしたタイトルは嘘ではないが, 実際の出来事の一部を誇張しており，クリックベイトであるといえる．(c) のケースはアイドルの写真集や DVD 発売イベントのニュースで多く見られる．特にグノシーでは図 5 に示すようにニュース記事リストのサムネイル画像を選択する際, 画像に人物が含まれる場合には人物の顔を中心にトリミングをしている．そのため, 画像全体を見たいというモチベーションがユーザには発生していると考えられる．(d) のケースは (c) と同様にアイドルの写真集や DVD 発売イベントのニュースにおいて, 写真集や DVD のあるシーンをタイトルにしているようなケースである．ユーザはそのシーンのような画像を期待して閲覧するが, そのシーンの画像は含まれておらず, 記者会見の画像があるのみである．ユーザがタイトルから抱いた期待を実際の内容が裏切っているという点から, こちらのケースもクリックベイトであるといえる．

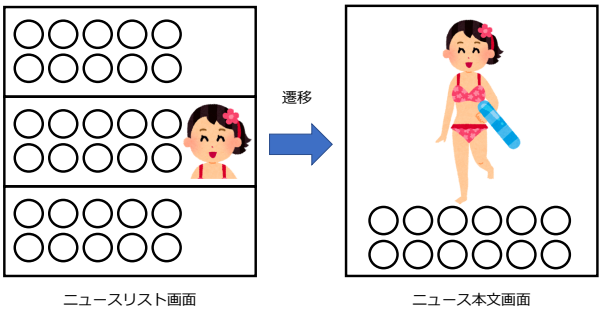

図 5　サムネイル画像がトリミングされるイメージ図

3.2 ニュース記事の分類

これらのケースを分類する方法を考える．文章をベースに考える (a),(b) のケースと, 画像をベースに考える (c),(d) のケースは分けて考えることができる．(a)(b) のケースはタイトルと本文が一致しているかということである．しかしタイトル自体に情報量がないケースも存在する．そのため, タイトルに十分な情報量があるかと, そのタイトルと内容が一致しているのかの 2 点を考える必要がある．(c)(d) のケースではまずタイトルが画像を想起するか, そして画像が想起される内容と一致しているかを考える必要がある．

以上を踏まえ, ニュース記事に対して以下の 4 つの設問を用意する．

（1） タイトルに十分な情報があるか

（2） タイトルと本文が十分に一致しているか

（3） タイトルが画像を想起されるか

（4） 適切な画像が本文にあるといえるか

今回は滞在時間が一定以下のニュース記事を著しく滞在時間が短いニュース記事とし,4 つの設問の回答を著者が 1 人で行った．対象となった記事数は 321 件である．理想的には様々な滞在時間のニュース記事に対して, クラウドソーシングなどを活用して様々な回答者から回答を集める必要があるが, 今回はそのような大規模な調査を行う前の試みとして行っている．

表 3.2 に全体の回答の結果を示す. 回答の内容は「ある」がクリックベイトではないニュース記事を表すようになっているが,2/3 程度が「ある」になっており, 滞在時間が短いニュース記事の中も多くのニュース記事がクリックベイトなニュース記

設問	ある	ない
(1) タイトルに十分な情報があるか	253	68
(2) タイトルと本文が十分に一致しているか	246	75
(3) タイトルが画像を想起されるか	273	48
(4) 適切な画像が本文にあるといえるか	209	112

表 2　ニュース記事に対する回答の結果

		(2)	
		ある	ない
(1)	ある	217	36
	ない	29	39

表 3　(1) と (2) のクロス集計

事ではない可能性を示唆している．対象の中で 85%のニュース記事が画像を想起するものであった．全体と比較していないので正確な議論はできないが，直感的には非常に高い割合であると考えられ，滞在時間が短いニュース記事の多くは画像を想起するようなタイトルを持っているといえる．

まず (1) と (2) の回答について詳しくみる．著者が (1) において情報がないと判断したのは「チーム A の選手が移籍した」というニュース記事で具体的にどの選手が移籍したかは本文を見なければ分からないようなニュース記事や,「A さんが「恥ずかしい」と言った」というニュース記事のように前提や対象を述べずに発言だけを切り出したようなニュース記事である．(1) と (2) の回答をクロス集計したものを表 3.2 に示す．約 2/3 が情報量があり, タイトルと内容が一致しているニュース記事であった．タイトルと内容が一致しているのは (a) に示したケースであり, クリックベイトなニュース記事ではないと考えられる．タイトルの情報量があるが内容と一致していない判断したニュース記事には記者会見等のの内容の一部のみをタイトルにしたものが多い．このようなニュース記事はタイトルを見たときの期待に閲覧した際に十分応えられているといえない (b) に示したケースであり, クリックベイトなニュース記事であると考えている．(1),(2) で両方「ない」とされたニュース記事は, 記者会見の内容の一部をタイトルにするだけではなく, その背景なども曖昧にしているニュース記事が多い．例えばある女優 A さんが過激な発言をしたかのように受け取れるタイトルのニュース記事がある. その内容は A さんが出席した記者会見に関するものであり, ニュース記事の多くはその記者会見について書かれている．そしてその過激な発言はあったが文脈的には自然な発言であり, タイトルを見たときの期待感とは大きく異るものである．このようなニュース記事は (b) に分類できクリックベイトなニュース記事であるといえるが, タイトルに情報量がある場合よりもより悪質であると考える．タイトルに情報量がないが, タイトルと本文が一致しているのは「チーム A の選手が移籍した」というニュース記事で, 本文には明確に選手名が記載されているようなニュース記事である．タイトルと本文が一致していないケースに比べると悪質な度合いは低いと考えられるが, ユーザに過度な期待を抱かせている可能性もある．このように設問の回答からタイトルと本文の関係性のパターンの類型化を行うことができた．

		(4)	
		ある	ない
(3)	ある	192	81
	ない	17	31

表 4　(3) と (4) のクロス集計

		(4)	
		ある	ない
(2)	ある	181	30
	ない	11	50

表 5　(2) と (4) のクロス集計

次に (3) と (4) の回答について詳しくみる．表 4 に (3) と (4) の回答をクロス集計したものを示す．適切な画像がないニュース記事は画像を想起するニュース記事全体の 3 割程度であった．これらのニュース記事は (d) に分類され，ユーザの期待に反しており，クリックベイトなニュース記事であると考えられる．画像を想起しない場合は適切な画像がなくても特にユーザに不利益があることはなく，また画像想起しない場合にも適切な画像が存在することもある．この 2 つの区分はクリックベイトなニュース記事には当たらない．

表 4 に (3) と (4) の回答をクロス集計したものを示す．タイトルと本文の一致と想起される画像の一致がどのように関係しているのかを見るために，(3) で画像が想起されるとされたニュース記事のみを対象に (2) と (4) のクロス集計を行ったものを表 3.2 に示す．タイトルと本文が一致していないとされたニュース記事のなかで、適切な画像があったニュース記事は 2 割を下回っており，タイトルと本文が一致していない場合は, 多くの場合で画像も一致していないといえる．また適切な画像があったニュース記事でタイトルと本文が一致していないニュース記事は 5%程度と画像が適切である場合はタイトルと本文が一致していることが多いこともいえる．このように画像がタイトルと一致しているかという点と，タイトルと本文が一致しているかという点はある程度関係していることが示唆された．

4. タイトルと本文の類似度を元にしたクリックベイトなニュース記事特定の試み

本章ではタイトルと本文の類似度を元に, クリックベイトなニュース記事の特定を試みる．前章の分析により, タイトルと本文が一致しているかを確認することによって, タイトルが過剰であるクリックベイトなニュース記事だけでなく, 想起される画像が存在しないようなニュース記事の多くも特定できることが示唆された．自然言語処理では文書をベクトル化し, その距離を求めることで文書間の類似度を測る方法が良く知られている．それらの手法がどの程度有効なのかを, 前章で作成したデータを元に確認する．前章で作成したデータは著者の主観を含むため, 本章の結果は十分信頼できるものとはいえないが, 将来的な大規模な分析やモデル化の方向性を考える上で有益な結果になると考えている．

4.1 文書のベクトル化

本節では本章で用いる文書のベクトル化手法について述べる．

近年では文書のベクトル化を行う際に Recurrent Neural Network などを利用して系列データとして扱う手法もよく用いられているが, 本章では文書を単語の集合としてみなす Bag-of-Words を用いる．つまり単語 w は語彙集合 W を用いて $w \in W$ と表現され, 文書 d は $d = \{w_1, ..., w_{N_s} : w_i \in W\}$ として表す．

ここで N_d は文書 d の文字数である.

文書 d の文書ベクトルを $\vec{d}$ として単語ベクトルと, その重み付け和として表現することにする. 単語 w の単語ベクトル $\vec{w}$ を返す関数を $\vec{w} = vec(w)$, $weight(w)$ を単語 w の重みを返す関数とすると, 文書ベクトル $\vec{d}$ は式 1 のようにかける.

$$\vec{d} = \sum_{w \in d} weight(w) \times vec(w) \tag{1}$$

つまり文書のベクトル化のためにはまず単語のベクトル化を考える必要がある. 単語のベクトル化手法として本章では one-hot ベクトル化と, 分散表現の 2 つを用いる. one-hot ベクトル化は単語 w を $|W|$ 次元のベクトル空間で, 対象となる単語 w を表す次元を 1, それ以外を 0 としたベクトルで表現する方法である. 分散表現は単語をある次元数のベクトルで表現する方法であり, 埋め込みベクトル, または word2vec ともよばれている. 本研究では CBOW によるベクトル化を, グノシーのニュース記事集合を用いて行った [4].

次に重み付け関数 $weight(w)$ について考える. 文書中の単語を重み付けする方法で最も知られている方法が TF-IDF である. 本章では TF-IDF と重み付けを行わない $weight(w) = 1$ とする方法の 2 つを用いる. 分散表現を TF-IDF に用いることによって要約の精度が改善することも報告されている [5]. 式 1 では $weight(w) = idf(w)$ とすることで TF-IDF と同様の重み付けを行うことができる.

以上のように文書のベクトル化の方法では以下の 4 つの方法を比較する

- one-hot ベクトル化+重み付けなし
- one-hot ベクトル化+TF-IDF
- 分散表現+重み付けなし
- 分散表現+TF-IDF

4.2 タイトルと本文の類似度の算出

前節では文書をベクトル化する方法について述べた. 本節ではタイトルと本文の類似度の算出方法について述べる. ベクトル化された文書の類似度を測る指標としてはコサイン類似度が一般的であり, 本研究でもコサイン類似度を用いることにする. そしてニュース記事のタイトルは, タイトルに含まれる単語の集合として扱う. ここではタイトルと比較する対象であるニュース記事の本文をどのように定義するかについて述べる.

ニュース記事本文の定義として最も一般的なものはニュース記事の本文に含まれる単語の集合として扱うことである. しかし今回特定したいニュース記事は, タイトルが本文の一部のみを誇張することで本文とタイトルが一致していないニュース記事である. つまりタイトルと一致していないとしたニュース記事でも全文には含まれていることから, 類似しているものとして判別される可能性がある.

そこでニュース記事では最初に概要が書かれていることが多いことから, そのニュース記事の中心となる内容を把握するために最初の部分を用いることが有効ではないかと考え, 本文の定義を以下の 4 通りで実験を行う.

- 1 文目のみを用いる
- 1 文目と 2 文目を用いる
- 最初の 10%の文を用いる
- 全文を用いる.

ここで文は句読点で区切られたものとする. 句読点がないニュース記事の場合は改行を文の区切りとする. またニュースの表現に関係ないと考えられる文については可能な限り前処理で除去した.

表 6 各手法による F 値

	one-hot ベクトル化		分散表現	
	重み付けなし	TF-IDF	重み付けなし	TF-IDF
1 文目	0.456	0.439	0.444	0.441
1 文目と 2 文目	0.460	0.444	0.484	0.462
前半 10%	0.440	0.441	0.440	0.442
全文	0.435	0.415	0.419	0.413

4.3 評　　価

本節ではここまでに示したベクトル化方法と本文の定義を比較する方法について述べる.

本研究の目的はクリックベイトなニュース記事を特定することにある. 本章では類似度が一定以下のニュース記事をクリックベイトなニュース記事だとした際に, 3. 章で作成した回答を用いて, どれだけがクリックベイトなニュース記事であったかを評価する.

手法の評価はクリックベイトなニュース記事をどれだけ特定できたかを F 値を用いて行う. Cosine 類似度を用いるため類似度は $[0, 1]$ の値域をとる. そこでしきい値を 0 から 1 まで 0.01 刻みで設定し, 最も F 値が大きいしきい値の F 値をその手法の評価とする.

4.4 結　　果

「タイトルと本文が一致していない」ニュース記事をクリックベイトなニュース記事としたときのそれぞれの手法の F 値を表 6 に示す. 最も F 値が高かった手法は分散表現を用いて TF − IDF の重み付けを行わず, 本文として 1 文目と 2 文目を用いた組み合わせであった.

TF-IDF 値を使って重み付けしたものより, 重み付けをしないほうが精度がよくなった要因には, 特徴的な語が一致していることが過度に類似度を高めてしまっていることが考えられる. 例えば「A さんと B さんが○○と言った」というタイトルのニュース記事において 1 文目が「A さんと B さんが記者会見に出席した」となっている場合,A さん,B さんといった人名が一致しており, このような人名の IDF 値が高い場合は類似しているとされるが, 今回の目的には適していない.

また 4.2 節で論じたように文書全体を使うより, 文頭の一部のみを使うほうが F 値は高くなった. 1 文目だけでなく 2 文目も使ったほうがよい結果になっているのは, 1 文目では日付や事実のみが記載され, 2 文目により詳細な内容が記載されているためであると考えられる. 一方でこの書き方はメディアやカテゴリの特性に依存するものであるため, 理想的にはどこまで用いるかという点についてもパラメータとして利用する必要があると考える.

分散表現と one-hot ベクトルの比較では，1 文目のみを用いたケースでは重み付けなしの one-hot ベクトルが最も高い F 値となっているが，これは一文目とタイトルが非常に類似しているケースをよく検出できていることが考えられる．本文のパターンによっては単純な一致を活用することも有効に働く可能性がある．

以上のように文書類似度を使ってクリックベイトとされるニュース記事を特定するために，ベクトル化手法と本文の選択方法について論じた．単純な方法では限界はあるものの，ある程度の特徴は考慮することができているといえる．この結果は実サービスでの価値検証のための簡易な方法として活用できるだけでなく，より大規模なデータセットを用意して教師あり学習を行う際のベンチマークとして利用できると考えられる．

5. ま と め

本研究ではクリックベイトなニュース記事を特定することを目的に，まずニュース記事の滞在時間を分析し，滞在時間と記事長の分布から，滞在時間が短いニュース記事を対象に分析を行うことにした．次に滞在時間が短いニュース記事を定性的に分析し，4 つのパターンを規定した．そして 4 つのパターンを分類することを目的に設問を設定し，その回答を用いて分類することで，クリックベイトなニュース記事の類型化を試み，タイトルと本文の類似性が重要な要素の一つであることを示した．そして作成したデータを元に，タイトルと本文の類似度を元にクリックベイトなニュース記事の特定を試みた．結果としてある程度分類することができ，実サービスでの活用のために一定の成果を得ることができた．また今後大規模な分析を行う際のベンチマークとしての活用も期待される．

今後はクラウドソーシングなどを活用して大規模な回答データを収集し，その分析を通して今回の仮説の妥当性を検証するとともに，大量のラベル付きデータを活用した教師あり学習によるクリックベイトなニュース記事の特定を試みる．またユーザフィードバックデータなどとも組み合わせ，サービス上でのユーザ行動と回答データの関係性についても議論していきたい．

文 献

[1] LINE 株式会社, 世代間のニュースサービス利用に関する意識調査, https://linecorp.com/ja/pr/news/ja/2016/1267, 2016.

[2] 藤代 裕之, ネットメディア覇権戦争 偽ニュースはなぜ生まれたか, 光文社, 2017.

[3] Gunosy、釣り記事を回避するアルゴリズムを研究開発, INTERNET WATCH, http://internet.watch.impress.co.jp/docs/news/1057945.html, 2017.

[4] Tomas Mikolov, Kai Chen, Greg Corrado, Jeffrey Dean, Efficient Estimation of Word Representations in Vector Space, ICLR, 2013.

[5] 田口 雄哉, 重藤 優太郎, 新保 仁, 松本 裕治, 抽出型文書要約における分散表現の学習 – 文書と要約の距離最小化 –, 第 23 回言語処理学会全国大会. 2017.