社団法人　電子情報通信学会
THE INSTITUTE OF ELECTRONICS,
INFORMATION AND COMMUNICATION ENGINEERS

信学技報
TECHNICAL REPORT OF IEICE.

等価性構造探索を効率化するための局所生起分布の性質調査

潮　　旭[†]　高橋　良暢[††]　佐藤　聖也[†††]　山川　　宏[††††,†††††]

† 慶應義塾大学
〒 223-8522 神奈川県横浜市港北区日吉 3-14-1
†† 電気通信大学
〒 182-8585 東京都調布市調布ケ丘 1-5-1
††† 産業技術総合研究所 人工知能研究センター
〒 135-0064 東京都江東区青海 2-4-7 産総研 臨海副都心センター別館
†††† (株) ドワンゴ ドワンゴ人工知能研究所
〒 104-0061 東京都中央区銀座 4-12-15　歌舞伎座タワー
††††† 全脳アーキテクチャイニシアティブ
E-mail: †ushioasahi@keio.jp, ††ytakahashi@ni.is.uec.ac.jp, †††seiya.satoh@aist.go.jp,
††††ymkw@wba-initiative.org

あらまし　等価性構造抽出技術は，特定の K 個の系列 ID で構成されるタプルにおいて局所時間内に生じる多様なパターンに着目し，パターンの出現が類似する ID タプルを要素とする集合を抽出するが，膨大な K 系列のペアに対応した類似度の計算が高コストとなる課題がある．本稿では，全ての等価な K 系列の ID タプルを得るには，同一の局所生起分布 (局所的時間で取り出した多変量データの各要素の生起分布) を含む K 次元の系列 ID 内で全ペアを比較すれば十分であることを示す．その上で計算コストを削減するため，頻出する局所生起分布のパターン数が少なくなる入力データの性質を調査して分析した．

キーワード　教師なし学習，視覚情報処理，クラスタリング，見まね学習

A Research for Efficient Equivalence Structure Search by Local Distribution of Variables

Asahi USHIO[†], Yoshinobu TAKAHASHI[††], Seiya SATOH[†††], and Hiroshi YAMAKAWA[††††,†††††]

† Keio University
2-15-45 Mita, Minato-ku, Tokyo 108-8345 Japan
†† The University of Electro-Communications
1-5-1 Chofugaoka, Chofu, Tokyo 182-8585, Japan
††† National Institute of Advanced Industrial Science and Technology (AIST)
AIST Tokyo Waterfront Bio-IT Research Building, 2-4-7, Aomi, Koto-ku, Tokyo 135-0064, Japan
†††† Dwango Artificial Intelligence Laboratory
KABUKIZA TOWER, 4-12-15 Ginza, Chuo-ku, Tokyo 104-0061, Japan
††††† The Whole Brain Architecture Initiative, a specified non-profit organization
E-mail: †ushioasahi@keio.jp, ††ytakahashi@ni.is.uec.ac.jp, †††seiya.satoh@aist.go.jp,
††††ymkw@wba-initiative.org

Abstract　Extract Equivalent Structures(ES) focuses on huge variety patterns of sequence-ID(N) appearing in local time and get the set composed of ID tuples which behave similarly. However, computing the similarity in large number of K-dimensional tuples take a lot of time is a severe problem. In this paper, we conduct the experiment to get pair or m-tuple of K-dimensional ID and show that it is sufficient to compare all of K-dimensional ID tuple that have equal short time pattern. In addition, we also investigate the case of small repertoire of short time patterns is frequently appearing.

Key words　unsupervised learning, visual processing, clustering, imitation learning

1. はじめに

機械学習などに用いられるデータ構造は多くの場合に，属性もしくは特徴量のベクトルの集合を一般化した関係モデルとして与えられるか、その形に変換される．そこで所与のデータから新たな関係モデルを自動的に生成できれば、様々な機械学習においてより柔軟に推論を行えるようになるだろう．本稿では，多次元時系列データから、複数の部分的な時系列を取り出して結合することにより新たな関係モデル [1] を生成する等価性構造抽出技術 [2] をベースとし，この実用性を高めるために計算量の削減を目指した技術について述べる．

多次元同期系列における，系列を識別するための ID の全体集合から取得することができる ID のタプルの中で，等価とみなせるもののペア，またはそれ以上のタプルを含む集合を等価性構造と呼ぶ [2]．等価性構造抽出は画像や動画等の系列データに対する特徴抽出，見まね学習を始めとした同期可能なデータ間の次元対応付け等種々の応用を考えることができる．

視覚入力を簡単化した点波シーケンスデータに対して，等価性構造の抽出が可能ことが示されている [2] 一方，任意の系列数で構成されるタプルの集合が，等価性構造である条件を満たすかどうかを比較検討する際に，その組み合わせ数が膨大であることから，計算量が指数時間となってしまう問題があった [2]．この問題に対し，本稿では系列を指定する ID ので構成される (系列)ID タプルで指定される多次元同期系列データにおける局所時間内に生じる様々なパターンに対して，着目する ID タプル内の各 ID を，局所時間内で生起しているかどうかの簡素な分布に置き換える前処理を加え，更に頻出する局所生起分布のパターン数が少数となる点波シーケンスデータに対する等価性構造の抽出を試みることで, [2] と同様の結果を得ながらに計算量を小さくすることに成功した．

本論文の構成は以下の通りである．2. 節では等価性構造とは何か，また等価性構造を取得することが可能な多次元同期系列 (入力データ) について説明する．次に，既存手法ではどのような手法で等価性構造を抽出していたのかについて記す．続く 3. 節では本稿で行った計算機実験の概要を示すとともに，局所生起分布という新しい概念を用いた本実験が結果に影響を与えることなく等価性構造を抽出できることを実験によって示す．4. 節ではまとめとして，等価性構造抽出に関するこれからの課題，また今後の展望を記す．

2. 準　　備

本節では，等価性構造がどのように定義されるかを説明するとともに，等価性構造を抽出する手順を関連知識とともに説明していく．

2.1 等価性構造 (Equivalence Structure)

N 次元同期系列である入力データを考える．系列指定子 (sequence ID) として $i\,(1 \leqq i \leqq N)$(以降，系列 ID と呼ぶ)，系列本体を系列 ID によって番号付けし，x_i とおく．また，時間を $t = (1, 2, \ldots, T)$ とおき，時間 t における系列の集合は $\boldsymbol{x^{(t)}}$ で表す．以上を図示すると，入力データは図 1 の左の図のように表現することができる．これは多次元同期系列において，ある系列内の値は時間 t が決まることでただ一つに決まりことを表し，その逆もまた然りであることが確認できる．値は系列 ID が i，時間が t において，$x_i^{(t)}$ とする．値として入るものは，具体的な例では 0 または 1 の二値が入力となったときにはある系列 x_i，時間 t に対して 0 または 1 のどちらかが入り，連続データが入力となるときには系列 x_i の時間 t における値が入る．

多次元同期系列から抽出する等価性構造は関係モデル (relational model) [1] に似た性質を持ち，以下のように定義することができる．

［定義 1］ 等価性構造

多次元同期系列の各系列 $x_i\,(1 \leqq i \leqq N)$ に割り振られる系列 IDi を値として保持する関係を考える．組として，系列 ID を要素として持つ ID タプルが定義される．これを単にタプル，または行タプルと呼ぶこととする．行タプルの数は M であり，ID タプルの指定子を $m\,(1 \leqq m \leqq M)$ とする．また列数は K とし，列として M 個全てのタプルから $k\,(1 \leqq k \leqq K)$ 番目の要素を取得する M-タプルを取得することができる．この取得できる M-タプルを射タプル (morphism tuple) と呼ぶ．射タプルは入力データの各系列 ID において，共通の性質を持つような系列 ID のタプルである．この共通の性質のことを特徴と呼ぶこととする．

上記の等価性構造が関係モデルと異なるところは，関係モデルが一般に異なる属性ごとに多様で相異なる属性値を持てることに対し，等価性構造は属性値が系列 ID のみしか存在しないこと，また関係モデルにおける属性が，値が入力される前に属性値が決定されることで何らかの意味付けができることに対し，等価性構造は入力データから値が抽出されて初めて各特徴に意味付けすることができることの二点である．このことから，等価性構造は行タプルの集合に特徴を見出すことで初めて見出し (ヘッダー) としての属性が付与され，関係データとして完成するものである．以上のことから，等価性構造は系列 ID を要素に持つ，関係する特徴の集合 (relational feature set) であると考えることができる．図示すると下図 1 の中央の図に示すようなモデルを考えることができる．

多次元同期系列から等価性構造を抽出する簡単な例として，図 1 の右の図のような場合が考えられる．この図は 8 次元同期系列を黒点が時間に従って推移していくような入力データから等価性構造を抽出した例である．この場合，系列 ID の $(2, 5, 1)$ という ID タプルと，$(1, 8, 6)$ という ID タプルが $\{(2, 5, 1), (1, 8, 6)\}$ のように等価性構造として抽出することができる．またこの例では射タプルとして $\{2, 1\}, \{5, 8\}, \{1, 6\}$ を特徴と呼ぶことができる．関連するモデルとしては，社会ネットワークの人物関係から隠れた関係があるかどうかを予測する Miller らによる latent feature relational model [3] や，それに時間的な変化を許す Foulds らによる dynamic relational infinite feature model [4] が有る．

次に入力データとなる多次元同期系列からどのようにして等価性構造を抽出するかを考える．

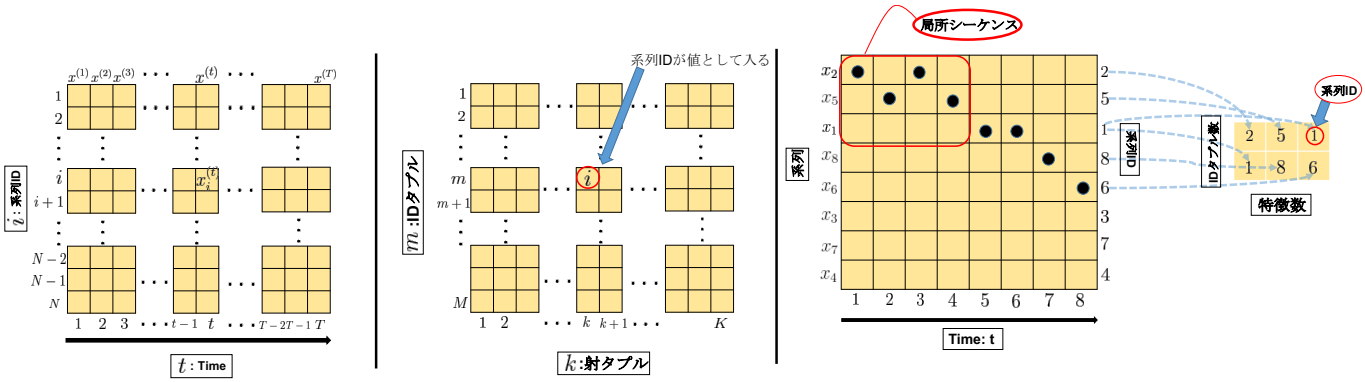

図 1　左: 入力データとなる多次元同期系列，中央: 系列 ID を値とする関係タブルの集合としての等価性構造，右: 8 次元同期系列 (0 または 1 を値としてもつ点波シーケンス) から等価性構造を抽出する例

2.2　多次元同期系列からの抽出

山川 [2] は，多次元同期系列から等価性構造を抽出する際に，図 1 の右の図の赤線略長方形に示すような，任意の個数の系列 (ID) と任意の長さの局所時間で構成される局所シーケンスを定義し，さらに各局所シーケンスを分類，比較するためにそれを LPT(Local Pattern Tensol) と呼ばれる高階二値テンソル表現を導入した．下図 2 は，図 1 に示す局所シーケンスが LPT に変換される様子である．局所シーケンスは入力データの全ての

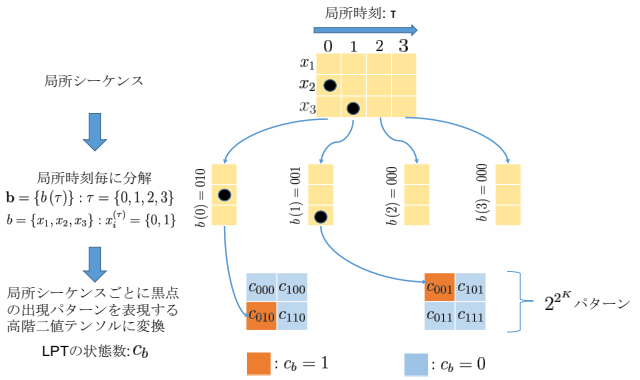

図 2　ある局所シーケンスを LPT に変換する例

範囲を覆うように動き，各局所シーケンスがどの LPT に当たるかが指定される．上記の手順を経て局所シーケンスをベクトル化して類似度比較への手順を踏んだ．しかし，LPT は取得する系列 ID の大きさを k とすると，全パターンを計算するのに 2^{2^k} 時間が必要になり，膨大な系列数の実データに適用する際にこの計算量が大きな課題になることは自明である．

2.3　局所生起分布

LPT を用いた状態表現では局所シーケンスが取りうる全てのパターンに対して高階二値テンソルを計算したが，本稿では前処理のために局所生起分布を用いる手法を導入する．局所生起分布とは，各局所シーケンスを取得した後，各系列において，黒点が現れたかどうかのみを見るものである．即ち取得する系列 ID の数 k に応じて 2^k 通りの二値表現が直ちに計算され，各局所シーケンスがどのパターンに当たるかを考える手法である．図 3 はある局所シーケンスが局所生起分布に変換される様子を表したものである．次節より等価性構造を抽出するための具体的な実験の説明をする．

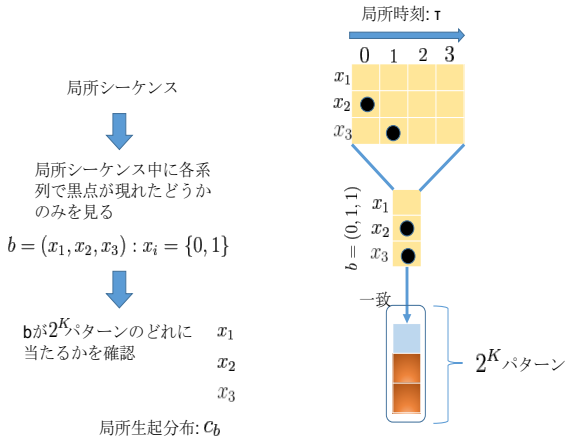

図 3　ある局所シーケンスを局所生起分布に変換する例

3.　計算機実験

本節では計算機実験により LPT 及び局所生起分布による等価性構造抽出を行い，それぞれで得られる等価性構造，計算時間の比較を行う．今回用いた系列データは 8×8 の二次元フレーム上で時刻 $t = 1 \sim 100$ で動く点データである．図 4 で実際に使用したフレームデータのイラストを示す．点の動き方は内部で一期間前の速度パラメータを保持する事により慣性のある動きになっており，フレームの各次元方向への時刻 t での位置は以下の式のように表す事ができる．

$$a_t = 0.8(a_{t-1} + u_t) \tag{1}$$

$$x_t = x_{t-1} + a_t \tag{2}$$

ここで a_t は速度パラメータ，x_t はフレーム上での位置，u_t は $[-1, 1]$ の一様分布からの確率変数である．点データが端に行き着いた場合は折り返すようにしている．透過性構造抽出の際，系列データの局所時刻は $\tau = \{0, 1, 2, 3, 4, 5, 6\}$ とした．

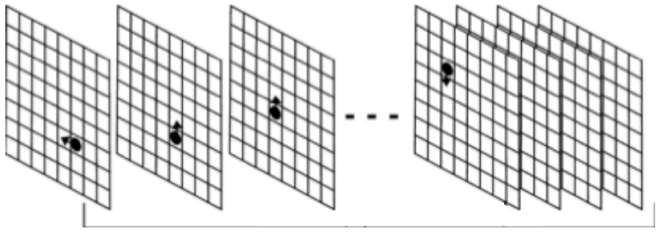

図 4　実験に使用した系列データのイラスト

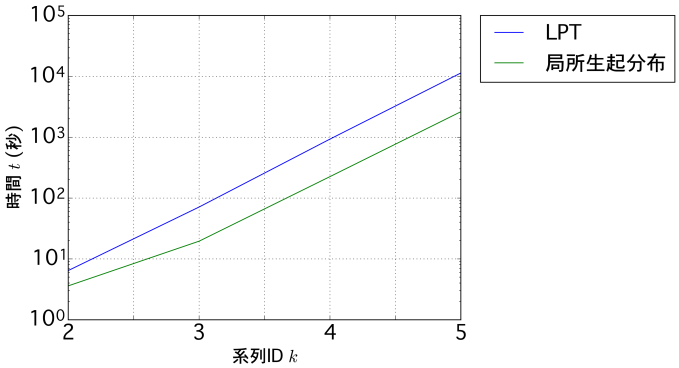

図 5　K 系列 に対する DEGs と局所生起分布による計算時間変化

実験結果を図 5, 表 1 に示す．局所生起分布の方が計算時間が少なくなっており，さらに系列 ID k が大きいほど計算時間の差は開いており $k = 2$ では約 2 倍ほどの差が $k = 5$ では約 4 倍になっている．

表 1　K 系列に対する DEGs と局所生起分布による計算時間 (秒)

k	2	3	4	5
DEGs	6.43	71.14	929.43	11333.11
局所生起分布	3.60	19.53	224.77	2618.56

4. 結　　論

等価性構造抽出技術に関し本稿では，全ての等価な K 系列の ID タプルを得るには，同一の局所生起分布を含む K 次元の系列 ID 内で全ペアを比較すれば十分であることを計算機実験により示した．さらに従来の等価性構造抽出技術である LPT を用いた状態表現と比較した際に大幅に計算コストを削減できる事を示した．今後の展望として，さらに一般的な系列データに対して局所生起分布による等価性構造抽出実験，及びアルゴリズムの提案などが考えられる．

謝辞　この成果は，国立研究開発法人新エネルギー・産業技術総合開発機構 (ＮＥＤＯ) の委託業務の結果得られたものです．また本研究を遂行するにあたり，ドワンゴ人工知能研究所の皆さまから多大なるご協力をいただきましたことに感謝致します．

文　　献

[1] Edgar F Codd. A relational model of data for large shared data banks. *Communications of the ACM*, Vol. 13, No. 6, pp. 377–387, 1970.

[2] 山川宏. 局所多次元時系列の関係表現としての性質の実験的検討. *Proceedings of JSAI2013*, No. 3H4-OS-05c-2in, 2013.

[3] Kurt Miller, Michael I Jordan, and Thomas L Griffiths. Nonparametric latent feature models for link prediction. In *Advances in neural information processing systems*, pp. 1276–1284, 2009.

[4] James R Foulds, Christopher DuBois, Arthur U Asuncion, Carter T Butts, and Padhraic Smyth. A dynamic relational infinite feature model for longitudinal social networks. In *AISTATS*, Vol. 11, pp. 287–295, 2011.